

土木工程计算机视觉
期末总结

1.计算机视觉工作流程:输入数据--感知器件--推理装备--解释结果

2.二维灰度图中 0 代表黑色，255 代表白色

彩色图（RGB）：3 个通道（R 红、G 绿、B 蓝），每个通道是 0-255 的矩阵，例如纯红是（255,0,0）

灰度图是单通道，可由彩色图通过加权平均转换（Y=0.299R+0.587G+0.114B），彩色图到灰度图有唯一解，反之不成立：不同的 RGB 组合可以映射到同一个灰度值，因此灰度图无法还原为唯一的彩色图。

3.基础任务：图像滤波、目标检测、语义分割。进阶任务：实例分割、全景分割

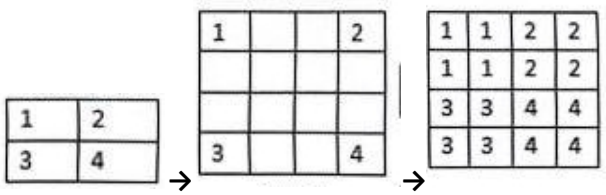
4.图像坐标系原点在左上角

5.下采样（压缩）（只失去一些局部信息）示例：6×6 → 3×3（2 倍下采样）

对于锐度高、清晰度高的图像（频率较高），下采样会丢失一些高频信息；下采样可以在一定程度上保留不变性（下采样多了就不保持了）;影响下采样的因素：下采样范围（一次采样多大的像素），框滑动的步长（通常 x，y 方向步长一致）

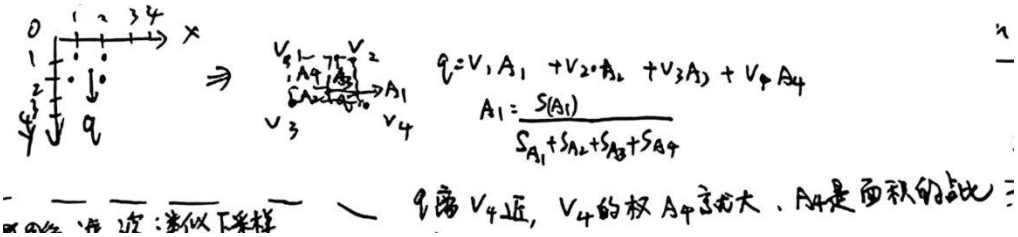
6.上采样（无唯一解）

最邻近插值：先把已知点放在角点，要插值的点与最近的已知点一致，信息不变



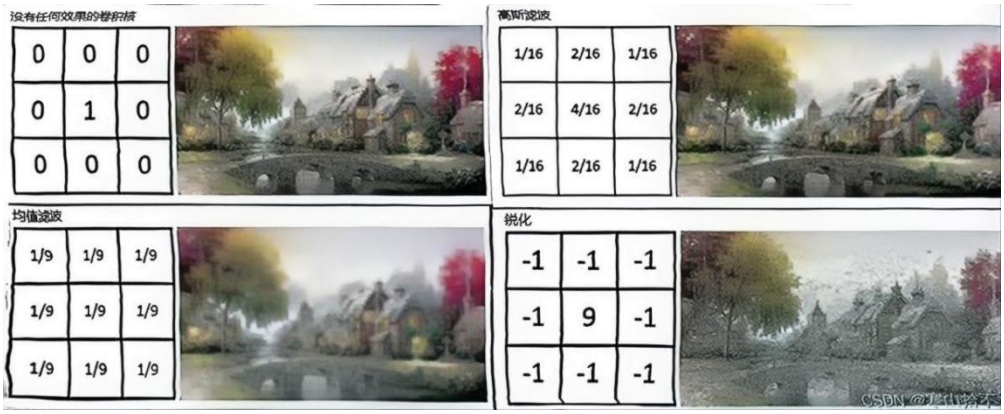
性质：局部光滑，难以体现纹理

双线性插值



7.图像滤波（类似下采样）

核中如果取均值：均值滤波；取中值为中值滤波；卷积核越大，得到的图像尺寸越小



8.图像梯度：图像梯度是图像像素值的变化率，用于提取边缘、特征点（如 SIFT、Harris 角点），本质是图像的一阶导数。

- **数学定义**：$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}\right)$，其中$\frac{\partial f}{\partial x}$是x方向（水平）梯度，$\frac{\partial f}{\partial y}$是y方向（垂直）梯度。
- **物理意义**：梯度的方向是图像灰度变化最快的方向（即边缘方向），梯度的模是变化的剧烈程度（边缘强度）：$|\nabla f| = \sqrt{(\frac{\partial f}{\partial x})^2 + (\frac{\partial f}{\partial y})^2}$。

数字图像是离散的像素矩阵，无法直接求导，因此用有限差分近似：

- **水平梯度（x方向，右减左）**：$G_x = f(x+1, y) - f(x-1, y)$
- **垂直梯度（y方向，下减上）**：$G_y = f(x, y+1) - f(x, y-1)$

梯度的模（边缘强度）

梯度的大小（模长）表示该点的边缘强度，值越大，边缘越明显：

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}$$

工程中为了简化计算，常使用近似：$|\nabla f| \approx |G_x| + |G_y|$

计算示例：

$$f = \begin{bmatrix} 10 & 20 & 30 \\ 40 & 50 & 60 \\ 70 & 80 & 90 \end{bmatrix}$$

- **坐标对应：**

$f(0,0) = 10,\ f(1,0) = 20,\ f(2,0) = 30$

$f(0,1) = 40,\ f(1,1) = 50,\ f(2,1) = 60$

$f(0,2) = 70,\ f(1,2) = 80,\ f(2,2) = 90$

2. 计算中心像素(1,1)的梯度

我们以最中间的像素 $(x = 1, y = 1)$ **(值为50)** 为例，计算它的梯度：

步骤1：计算水平梯度 G_x

$G_x = f(x+1, y) - f(x-1, y) = f(2,1) - f(0, 1) = 60 - 40 = 20$

含义：水平方向，右侧像素(60)比左侧像素(40)亮20，水平变化率为20。

步骤2：计算垂直梯度 G_y

$G_y = f(x, y+1) - f(x, y-1) = f(1,2) - f(1, 0) = 80 - 20 = 60$

9.图像变换

齐次坐标表示(x,y,w)对应笛卡尔坐标为（x/w, y/w).当 w=0 时，(x,y,0)表示 (∞,∞)，表达无穷远点

此外，齐次坐标可将平移、旋转等统一为矩阵乘法

1. 齐次坐标平移公式

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

- 平移后笛卡尔坐标：$(x', y') = (x + t_x, y + t_y)$
- 核心作用：用矩阵乘法统一表示「平移 + 线性变换」，解决笛卡尔坐标平移无法用矩阵乘法表示的问题
- 补充：$[t_x\ t_y]^T$ 为原笛卡尔坐标的平移向量

自由度（未知量个数）为 n，n 为维度，平移保方向

2.笛卡尔坐标系下的旋转矩阵，保距离

将某点逆时针旋转θ角度,旋转矩阵R_θ满足$|R_\theta|=1, R_\theta^T=R_{-\theta}, R_\theta R_\theta^T=R_0=E$

$\begin{matrix} x' \\ y' \end{matrix}=\begin{matrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{matrix} * \begin{matrix} x \\ y \end{matrix}$放在齐次坐标系$\begin{matrix} x' \\ y' \\ 1 \end{matrix}=\begin{matrix} \cos\theta & -\sin\theta & \\ \sin\theta & \cos\theta & \\ & & 1 \end{matrix} * \begin{matrix} x \\ y \\ 1 \end{matrix}$，自由度 1

如果既旋转又平移，则 $\begin{bmatrix} \cos\theta & -\sin\theta & t_x \\ \sin\theta & \cos\theta & t_y \\ & & 1 \end{bmatrix}$

三维旋转矩阵，R_θ表示 xoz 平面，R_φ表示 yoz 平面，R_ψ表示 xoy 平面

$R_\theta=\begin{bmatrix} \cos\theta & -\sin\theta & \\ \sin\theta & \cos\theta & \\ & & 1 \end{bmatrix}$，$R_\varphi=\begin{bmatrix} 1 & & \\ & \cos\varphi & -\sin\varphi \\ & \sin\varphi & \cos\varphi \end{bmatrix}$，$R_\psi=\begin{bmatrix} \cos\psi & & -\sin\psi \\ & 1 & \\ \sin\psi & & \cos\psi \end{bmatrix}$

$R=R_\psi R_\varphi R_\theta$，旋转次序不能变，$R^TR=RR^T=E$（正交），自由度 3

$$\begin{bmatrix} x1' \\ x2' \\ x3' \\ 1 \end{bmatrix} = \begin{bmatrix} R_\psi R_\varphi R_\theta & \\ & 1 \end{bmatrix} \begin{bmatrix} x1 \\ x2 \\ x3 \\ 1 \end{bmatrix}$$ N 维，自由度 m=n(n-1)/2 $$\begin{bmatrix} x1' \\ x2' \\ \dots \\ xn' \\ 1 \end{bmatrix} = \begin{bmatrix} R_{\theta m} * \dots * R_{\theta 1} & \\ & 1 \end{bmatrix} \begin{bmatrix} x1 \\ x2 \\ \dots \\ xn \\ 1 \end{bmatrix}$$

刚体变换：仅包含旋转 + 平移，弹性体变换：伸缩

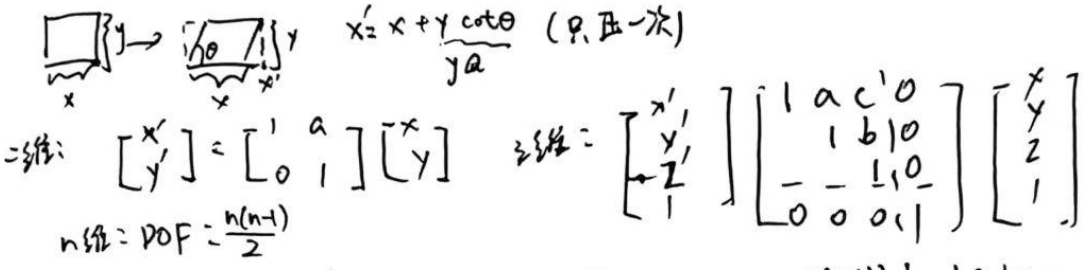
3.伸缩，保夹角

笛卡尔：一维 $x'=S_xx$,二维 $\begin{bmatrix} x' \\ y' \end{bmatrix}=\begin{bmatrix} Sx & \\ & Sy \end{bmatrix}\begin{bmatrix} x \\ y \end{bmatrix}$

齐次：$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix}=\begin{bmatrix} Sx & & \\ & Sy & \\ & & 1 \end{bmatrix}\begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$ $\begin{bmatrix} x' \\ y' \\ z' \\ 1 \end{bmatrix}=\begin{bmatrix} Sx & & & \\ & Sy & & \\ & & Sz & \\ & & & 1 \end{bmatrix}\begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$

等比缩放：Sx=Sy，$\begin{bmatrix} x' \\ y' \end{bmatrix} = S\begin{bmatrix} x \\ y \end{bmatrix}$，DOF=1,若非等比，则 DOF=2

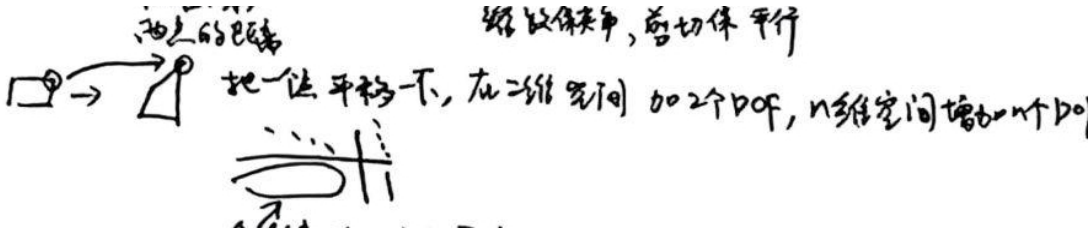
4.剪切：x'=x+ya，保平行



5.仿射变换：平移-（失去保方向）-旋转-（失去保距离）-伸缩-（失去保夹角）-剪切

N 维仿射变换，DOF=n（n+1）（全做一遍），三维：$\begin{bmatrix} a & b & c & tx \\ d & e & f & ty \\ g & h & i & tz \\ & & & 1 \end{bmatrix}$

6.射影变换



7.对称变换 DOF=0，元素都是 0,1，-1，没有未知量

1）二维平面：关于x轴的反射

变换公式：$\sigma\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \\ -y \end{pmatrix}$

对应矩阵：$A = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$，满足$A^T = A$

2）二维平面：关于y轴的反射

变换公式：$\sigma\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -x \\ y \end{pmatrix}$

对应矩阵：$A = \begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix}$，对称矩

3）三维空间：关于xy平面的反射

变换公式：$\sigma\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} x \\ y \\ -z \end{pmatrix}$

对应矩阵：$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix}$，对称矩阵

8.累积 DOF

	平移	旋转	缩放	剪切	射影
2 维	2	3	5	6	8
3 维	3	6	9	12	15
N 维	+N	+C(N,2)	+N	+C(N,2)	+N

9. 相机内外参：相机外参 $\vec{\mathbf{x}}_{\mathbf{img}} = \mathbf{K}[\mathbf{R} \quad \vec{\mathbf{t}}]\vec{\mathbf{X}}_{\mathbf{w}}$，相机内参$\vec{\mathbf{x}}_{\mathbf{img}}=\mathbf{P}\vec{\mathbf{X}}_{\mathbf{w}}$

其中$\vec{\mathbf{x}}_{\mathbf{img}}$是图像中坐标，相机内参：焦距等相机参数，同一相机内参不变，$[\mathbf{R} \quad \vec{\mathbf{t}}]$是相机外参（代表真实世界的旋转平移，只有旋转和平移），$\vec{\mathbf{X}}_{\mathbf{w}}$是真实世界的坐标

10.神经网络：多层感知机 (MLP)神经网络概述

最简单网络：输入层 x-隐藏层 h-输出层 y，复杂度 xh+hy

通用近似定理：一个具有至少一个隐藏层且神经元数量足够的前馈神经网络，可以逼近紧致集上任意连续函数。

激活函数：(特点：连续可导，允许少数点不可导，自身及导数尽可能简单，导数值域要在合适区间，不必单调递增，多层网络允许某几层没有激活函数，但是不能都没有，作用：增加非线性效应，无非线性的多层网络相当于单层)：ReLU(x)=(x+|x|)/2,右侧 sigmoid

无非线性的多层网络$\boldsymbol{X^l = w^{l-1}\otimes(\ldots w^2\otimes(w^1\otimes x^1 + b^1) + b^2\ldots) + b^{l-1} = \prod_{i=1}^{l-1} w^i \otimes x^1 + [b^{l-1} + \sum_{i=1}^{l-2}(b^i \prod_{j=i+1}^{l-1} w^j)}$

标准ReLU

公式：$\sigma(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} = \max(0, x)$

导数：$\sigma'(x) = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases}$ ($x=0$处导数不可导，通常取0或1)

输出范围：$[0, +\infty)$

PReLU（参数化ReLU）

公式：$\mathrm{PReLU}(x) = \begin{cases} x, & x > 0 \\ \gamma x, & x < 0 \end{cases}$ (γ为可学习参数，通常初始化为0.25)

导数：$\mathrm{PReLU}'(x) = \begin{cases} 1, & x > 0 \\ \gamma, & x < 0 \end{cases}$

输出范围：$(-\infty, +\infty)$

公式：$\sigma(x) = \frac{1}{1+e^{-kx}}$

导数：$\sigma'(x) = \frac{ke^{-kx}}{(1+e^{-kx})^2} \leq \frac{k}{4}$ (当$x=0$时取最大值$\frac{k}{4}$)

Leaky ReLU（带泄露ReLU，PReLU的固参数版）

公式：$\mathrm{Leaky\ ReLU}(x) = \begin{cases} x, & x > 0 \\ \gamma x, & x \leq 0 \end{cases} = \max(0, x) + \gamma\min(0, x)$ (γ为固定超参数，通常取0.01)

导数：$\mathrm{Leaky\ ReLU}'(x) = \begin{cases} 1, & x > 0 \\ \gamma, & x < 0 \end{cases}$

输出范围：$(-\infty, +\infty)$

ELU（指数线性单元）

公式：$\mathrm{ELU}(x) = \begin{cases} x, & x > 0 \\ \gamma(e^x - 1), & x \leq 0 \end{cases} = \max(0, x) + \min(0, \gamma(e^x - 1))$ (γ通常取1)

导数：$\mathrm{ELU}'(x) = \begin{cases} 1, & x > 0 \\ \mathrm{ELU}(x) + \gamma, & x < 0 \end{cases}$

输出范围：$(-\gamma, +\infty)$

Softplus（ReLU的平滑近似）

公式：$\mathrm{softplus}(x) = \log(1 + e^x)$

导数：$\mathrm{softplus}'(x) = \frac{1}{1+e^{-x}} = \sigma(x)$ (即Sigmoid函数)

输出范围：$(0, +\infty)$

11.网络训练

训练集$D = \{(x^{(n)}, y^{(n)})\}_{n=1}^{N}$，将 $x^{(n)}$ 输入，输出 $y^{(n)}$，其在 D 上的结构化风险函数为

$$R(w,b) = \frac{1}{N}\sum_{n=1}^{N} L(y^{(n)}, g^{(n)}) + \frac{\lambda}{2}\|w\|_p^2$$

，梯度下降

$$w^{(t)} = w^{(t-1)} - \alpha\frac{\partial R(w,b)}{\partial w^{(t)}}, \quad b^{(t)} = b^{(t-1)} - \alpha\frac{\partial R(w,b)}{\partial b^{(t)}}$$

对于分类$\mathbf{L} = -\frac{1}{N}\sum_{i=1}^{N}\log\left(\frac{e^{z_{ij}}}{\sum_{k=1}^{c} e^{z_{ik}}}\right)$，$\frac{e^{z_{ij}}}{\sum_{k=1}^{c} e^{z_{ik}}}$是 softmax，z 是末端神经元输出，c 是类别总数回归$\mathbf{L} = \frac{1}{N}\sum_{i=1}^{N}\sum_{t=1}^{M}\left(y_t^i - \hat{y}_t^i\right)^2$

分类任务输入图像输出独热向量{1,0,0...0}，多分类 softmax：y=$\underset{c=1}{\overset{c}{\mathbf{argmax}}}\, f_c(x;\ w_c)$，

softmax（x_k）=exp（x_k）/∑（i=1 到 k）exp（x_i），取指数可放

大不同类别的差异，$\mathbf{P(y=c|x)=softmax(w_c^T x)} = \frac{\mathbf{e^{w_c^T x}}}{\sum_{\mathbf{i=1}}^{\mathbf{c}} \mathbf{e^{w_i^T x}}}$

其中 argmax 直译为最大值对应的自变量，对于函数 y=f(x)若 x0=argmax(f(x))，表示当 x=x0 时，

f(x)取得最大值；若存在多个点使 f(x)取得相同最大值，则 argmax 结果为点集。

12.softmax 多分类交叉熵梯度推导：反传时 pi 可正向获得，yi 是标签，不需真的求导

Softmax 输出$\boldsymbol{pi} = \frac{\boldsymbol{exp(fi)}}{\sum_{\boldsymbol{k=1}}^{\boldsymbol{c}} \boldsymbol{exp(fk)}}$,其中 fi 是模型对第 i 类的线性输出，c 是类别总数；交叉熵损失$\boldsymbol{L} = -\sum_{i=1}^{c} \boldsymbol{yilogpi}$,其中 yi 是真实标签，独热编码；对损失 L 关于 pj 求偏导 $\frac{\partial L}{\partial p_j} = \frac{\partial}{\partial p_j}\left(-\sum_{i=1}^{c} y_i \log p_i\right) = -\frac{y_j}{p_j}$，因为只有当 i=j 时，$\frac{\partial \log p_i}{\partial p_j} = \frac{1}{p_j}$，其余项为 0；对 Softmax 输出 pj 关于 fi 求偏导，分两种情况：j=i 时$\frac{\partial p_i}{\partial f_i} = \frac{\partial}{\partial f_i}\left(\frac{e^{f_i}}{\sum_{k=1}^{c} e^{f_k}}\right)$，用商的导数法$= \frac{e^{f_i} \cdot \sum_{k=1}^{c} e^{f_k} - e^{f_i} \cdot e^{f_i}}{\left(\sum_{k=1}^{c} e^{f_k}\right)^2} = \frac{e^{f_i}}{\sum_{k=1}^{c} e^{f_k}} \cdot \left(1 - \frac{e^{f_i}}{\sum_{k=1}^{c} e^{f_k}}\right) = p_i(1 - p_i)$，j≠i 时$\frac{\partial p_j}{\partial f_i} = \frac{\partial}{\partial f_i}\left(\frac{e^{f_j}}{\sum_{k=1}^{c} e^{f_k}}\right) = \frac{0 \cdot \sum_{k=1}^{c} e^{f_k} - e^{f_j} \cdot e^{f_i}}{\left(\sum_{k=1}^{c} e^{f_k}\right)^2} = -\frac{e^{f_i} e^{f_j}}{\left(\sum_{k=1}^{c} e^{f_k}\right)^2} = -p_i p_j$；链式法则求 $\frac{\partial L}{\partial f_i} = \sum_{j=1}^{c} \frac{\partial L}{\partial p_j} \cdot \frac{\partial p_j}{\partial f_i} = \frac{\partial L}{\partial p_i} \cdot \frac{\partial p_i}{\partial f_i} + \sum_{j \neq i} \frac{\partial L}{\partial p_j} \cdot \frac{\partial p_j}{\partial f_i} = \left(-\frac{y_i}{p_i}\right) \cdot p_i(1 - p_i) + \sum_{j \neq i} \left(-\frac{y_j}{p_j}\right) \cdot \left(-p_i p_j\right) = -y_i(1 - p_i) + p_i \sum_{j \neq i} y_j = p_i - y_i$

yi 是标签，fi 是神经网络最后一层的输出

13.梯度下降：$w^l \leftarrow w^l - \eta \frac{\partial L}{\partial \omega^l}$，$\eta$为学习率，$\frac{\partial L}{\partial \omega^l} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial \omega^l}$，$z = \sigma\left(\omega^l \otimes x^l + b^l\right)$，$\frac{\partial z}{\partial \omega^l} = \sigma' * x^l$，$\frac{\partial z}{\partial b^l} = \sigma'$

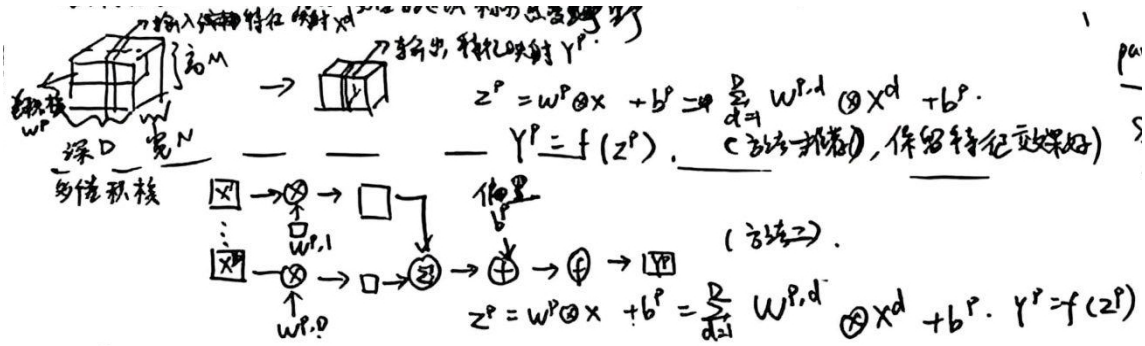
14.卷积神经网络（CNN）

全连接前馈神经网络的局限性：权重矩阵参数非常多，局部不变性特征提取困难。尺度不变性指尺度缩放平移旋转等操作不影响其语义信息，全连接前馈神经网络很难提取这些局部不变特征

卷积参数：卷积核大小，卷积核内部参数，滑动步距，补 0 数（四个方向），卷积核的深度（如果原图带深度），卷积核的数量

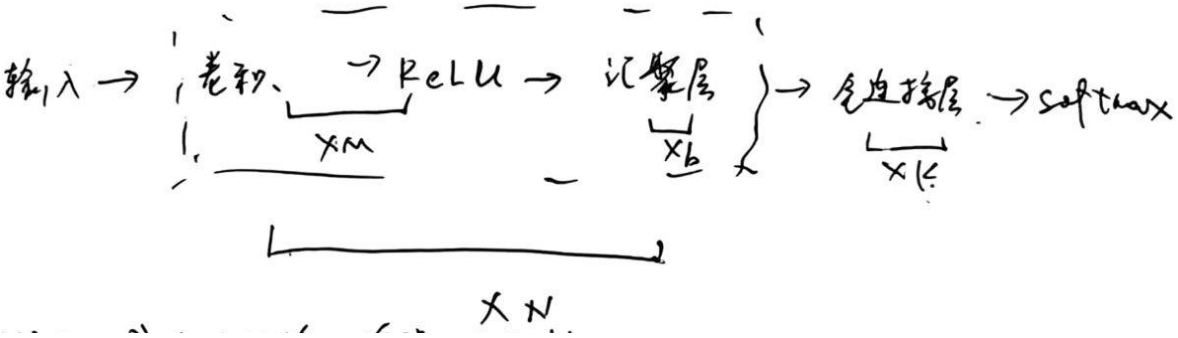
卷积：Y=WX，$\mathbf{y_{ij}} = \sum_{\mathbf{u=1}}^{\mathbf{U}} \sum_{\mathbf{v=1}}^{\mathbf{V}} \mathbf{w_{uv}}\, \mathbf{x_{i-u+1,j-v+1}}$，其中 yij 指卷积后 ij

位置像素值，wuv 指 uv 位置卷积核权重
多通道卷积：输入：深度为 D 的特征图，输出：得到深度为 P 的特征图，每个特征图上的点对应原始图像的区域称为感受野
增加感受野方法：增加卷积核大小，增加（CNN）层数，在卷积核之前池化，空洞卷积
空洞卷积：R（rate）:空洞率，相邻两元素之间的空洞数量
多通道图像卷积两种方法：第一种方法对每个输出通道都有一组独立的卷积核，第二种方法给每个输入通道 D 都配一个独立的卷积核，大幅度减少参数量



池化：max pooling（能提取边界，保留图像中最显著特征），y= $\max_{i,\ j}(x_{i,j})$

Average pooling:Y= $\mathrm{mean}_{i,\ j}(x_{i,j})$，默认情况下，2×2 池化的滑动步距（stride）是 2，这样池化窗口不会重叠，能刚好将特征图尺寸减半。
CNN 网络结构：输出-卷积激活池化-卷积激活池化-全连接-softmax



卷积：$\mathbf{H^{l+1}=1+\frac{H^{l}-H'^{l}+P_H^{l+}+P_H^{l-}}{S_H^{l}}}$，其中 H 是图像尺寸，H'是卷积核尺寸，S 是滑动
步距，P 是补 0 数，正负表示沿正向负向，卷积实现将低阶初级特征转化为高阶抽象特征的过程
转置卷积：也叫反卷积，是卷积的逆向过程，已知输出 H(l+1) 求输入 H(l)，对图像进行上采样，将小尺度图像转化为大尺度图像
$\mathbf{H^{l}=(H^{l+1}-1)S_H^{l}+H'^{l}-P_H^{l+}-P_H^{l-}}$，认为 H(l+1)为输出，对调得
$\mathbf{H^{l+1}=(H^{l}-1)S_H^{l}+H'^{l}-P_H^{l+}-P_H^{l-}}$，空洞卷积 $\mathbf{H^{l+1}=1+}$

$\frac{H^{l}-R_{H}\left(H'^{l}-1\right)+P_{H}^{l+}+P_{H}^{l-}-1}{S_{H}^{l}}$,R 为空洞率：感受野相邻元素间空洞数量+1

全卷积：1*1 卷积核，滑动步距 1

随机失活 dropout：让每次前向传播时随机设置一些神经元不工作，比例为失活率，一般 0.5，可减少过拟合，增强泛化性

15.信息论与图像分类：

自信息：$I(x)=-\log P(x)$，表示单个事件 x 发生时携带的信息量，概率越小，自信息越大。熵$H(x)=E_{x}[I(x)]=-\sum_{x\in X}P(x)\log P(x)$，描述随机变量的不确定性，熵越高，随机变量的不确定性越大（信息越混乱）

交叉熵$H(p,q)=E_{p}[-\log q(x)]=-\sum_{x}P(x)\log q(x)$衡量两个概率分布 p（真实分布）和 q（预测分布）的差异。p 与 q 越接近，交叉熵越小。

KL 散度$KL(p,q)=H(p,q)-H(p)=\sum_{x}P(x)\log\frac{P(x)}{q(x)}$表示用分布 q 近似分布 p 时的信息损失。

二分类交叉熵损失$L=-[y\cdot\log(\hat{p})+(1-y)\cdot\log(1-\hat{p})]$：模型对单个样本的预测概率为 p^（正类的概率），真实标签为 y（y=1 表示正类，y=0 表示负类）。

当 y=1 时，损失简化为−log(p^)，p^越接近 1，损失越小。

当 y=0 时，损失简化为−log(1−p^)，p^越接近 0，损失越小。

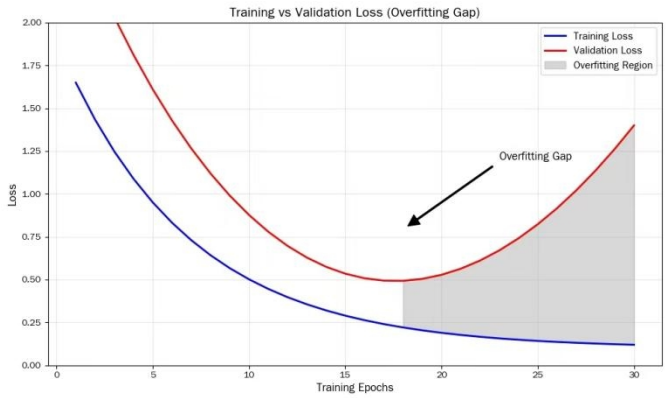
多分类判别函数$f_{c}(x;w_{c})=w_{c}^{T}x+b_{c}$多分类任务需要 C 个判别函数，将多分类转化为多个二分类问题。

多分类交叉熵损失$L(h(x),y)=-\sum_{k=1}^{C}y_{k}\log\hat{P}(y=k|x)$：假设样本有 C 个类别，真实标签用 one-hot 向量 y（只有对应类别为 1，其余为 0），模型预测的类别概率为 p^1,p^2,…,p^C。只有真实类别对应的 yk=1，所以损失只关注该类别预测概率的对数。模型预测越接近真实分布，损失越小。

16.图像识别使用卷积：减少参数量，捕获平移不变性（卷积核会平移，且参数不变）

池化（下采样）：获得更强的变形不变性（例如最大池化保留最大特征），使小卷积核增大感受野

17.Overfitting gap：蓝色曲线（Training Loss）：随着训练轮次增加持续下降，模型在训练集上表现越来越好；红色曲线（Validation Loss）：前期与训练损失同步下降，在约第 15 轮后开始上升，与训练损失之间形成明显的 Overfitting Gap（过拟合间隙）；灰色阴影区域：标注了过拟合发生的阶段，此时模型开始 “死记硬背” 训练数据，泛化能力下降

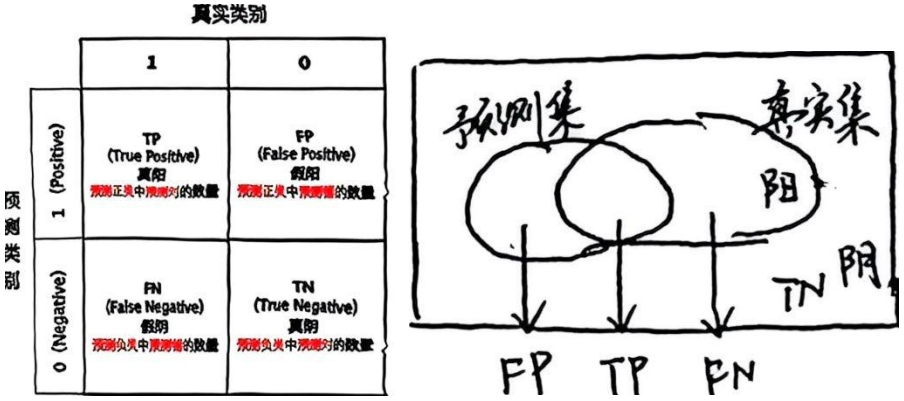


控制过拟合：减少参数量，增大数据集大小（数据增强：基础几何变换（翻转、随机裁剪、旋转、仿射变换）；颜色调整（亮度、对比度、饱和度），灰度化，打乱 rgb 通道，噪声注入，模糊/锐化，局部遮挡），随机失活 dropout

18.混淆矩阵

TP：预测为正、实际为正（真正例）；**FP**：预测为正、实际为负（假正例）

FN：预测为负、实际为正（假负例）；**TN**：预测为负、实际为负（真负例）



准确率（accuracy）=（TP+TN）/N,全局视角

$$\text{精确率（Precision）}=\frac{\mathbf{TP}}{\mathbf{TP+FP}};\ \text{召回率（Recall）}=\frac{\mathbf{TP}}{\mathbf{TP+FN}};$$

$$\text{F1分数}=\frac{2}{\frac{1}{\mathbf{Precision}}+\frac{1}{\mathbf{Recall}}}=\frac{2\times\mathbf{Precision}\times\mathbf{Recall}}{\mathbf{Precision}+\mathbf{Recall}}$$

召回率可对漏判进行控制，精确率对误判进行控制

19.梯度爆炸/消失

原因：反向传播中，每一层的梯度都要乘以当前层激活函数的导数和权重矩阵。设网络有 L 层，第 i 层的输出为z_i，激活函数为σ，权重为W_i。反向传播时，损失 L 对第 1 层权重的梯度为：$\frac{\partial L}{\partial W_1}=\frac{\partial L}{\partial z_L}\cdot\underbrace{\frac{\partial z_L}{\partial z_{L-1}}\cdot\frac{\partial z_{L-1}}{\partial z_{L-2}}\cdots\frac{\partial z_2}{\partial z_1}}_{\text{连乘项}}$,

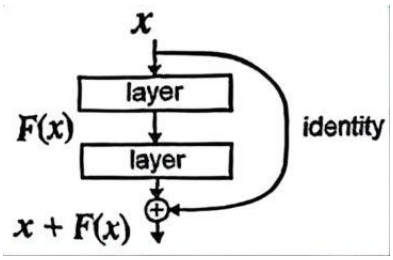
其中每一项$\frac{\partial z_{i+1}}{\partial z_i}=W_i^T\cdot\sigma'(z_i)$，梯度消失的主要诱因：以 Sigmoid 激活函数为例：

- Sigmoid 的导数最大值只有 0.25，且大部分区间的导数都远小于 1，当网络很深时，连乘 0.25* 0.25*... 会指数级衰减，梯度很快就趋近于 0。其他如 tanh 也有类似问题，只是导数

最大值为 1，衰减速度稍慢;梯度爆炸的主要诱因:如果权重矩阵的初始值很大，连乘后梯度会指数级增长，导致数值溢出.某些激活函数（如 ReLU 在输入大于 0 时导数为 1，但如果是类似指数型的激活函数，导数可能大于 1），连乘后会让梯度不断放大。

解决方法：残差连接：公式$\mathbf{Z_{i+1}} = \mathbf{g_i}(\mathbf{Z_i}, \mathbf{W_i}) + \mathbf{Z_i}$，对应的梯度为：$\frac{\partial \mathbf{z_{i+1}}}{\partial \mathbf{z_i}} = \frac{\partial \mathbf{g_i}}{\partial \mathbf{z_i}} + \mathbf{1}$

即使残差分支的梯度$\frac{\partial \mathbf{g_i}}{\partial \mathbf{z_i}}$很小，加上 1 之后，整体梯度也不会消失。



问题：不同层级的图尺寸不一样，不能直接加 Zi，解决：跨层级时可通过下采样/1*1 卷积增加通道数，两种方法的参数量都很少

20.迁移学习

迁移学习就是把已经训练好的模型和权重直接纳入到新的数据集当中进行训练，但是我们只改变之前模型的分类器（全连接层和 softmax/sigmoid）

也就是：图像--特征提取器（冻结）--分类器（微调）--分类结果

Top-k：当分类类别较多，取前 k 个最大分类概率的结果，例如 Top-5 意为前 5 个只要有一个最大的就认为正确

21.目标检测（分为图中仅单一类别和图中多类别），是在整张输入图像中，定位出所有感兴趣物体的位置，同时识别出每个物体的类别。输出框的中心点和长宽以及框内物体类别

常用任务：人脸识别（单类别：姿态（侧脸 / 低头）、光照（强光 / 逆光 / 暗光）、表情、年龄、遮挡（口罩 / 眼镜 / 帽子）导致人脸特征畸变；同一人不同状态特征差异大，不同人（双胞胎 / 相似脸）特征相似度高；复杂背景干扰、图像模糊 / 低分辨率、跨设备成像差异（像素 / 色域不同））

行人检测（尺度与姿态多变：行人身高 / 距离差异大（远距小目标 / 近距大目标），行走 / 弯腰 / 抬手等姿态无固定形态；严重遮挡：人群密集、车辆 / 建筑遮挡，常出现仅露头部 / 半身的情况，特征不完整；场景复杂：逆光 / 雨夜 / 雾天等恶劣环境，阴影、反光、相似背景（如栏杆 / 树木）干扰；密集人群检测：目标框高度重叠，NMS 易误删正样本，特征融合难度大）

通用目标检测（背景复杂（遮挡 / 干扰）、目标形态多变（姿态 / 尺度 / 光照）、类别不平衡）

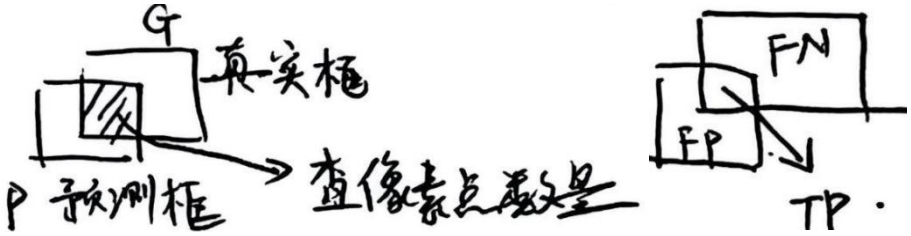
常用数据集：

PASCAL VOC 经典入门基准，分 VOC2007/VOC2012，共 20 类通用目标（人、车、家具、动物等），标注含目标检测 / 分类 / 分割，数据量适中（VOC2012 共 1.7 万张图），适合算法入门、小模型训练、性能快速验证，是目标检测的基础评测标准。

MS COCO 业界最核心的通用目标检测基准，远超 VOC 的规模和难度，含 80 类通用目标，超 33 万张标注图、150 万个目标框，支持目标检测、实例分割、关键点检测等多任务；

核心特点是目标尺度差异大、密集目标多、背景复杂，完美贴合真实场景，是目前几乎所有通用检测算法的主流评测数据集。

22.目标检测评价指标



核心评价指标：（1）IOU（交并比）= $\frac{\mathbf{Area(P\cap G)}}{\mathbf{Area(P\cup G)}}=\frac{\mathbf{TP}}{\mathbf{TP+FP+FN}}$

作用：衡量预测框与真实框的重叠程度，是目标检测的基础指标。

局限性：当不同形态的框 IOU 相同时，无法区分优劣。当两框无重叠时 IOU 恒为 0

非最大值抑制：同一物体有多个预测框时一般取 IOU 最大的框

（2）查准率（Precision）=$\frac{\text{正确检测数}}{\text{总检测数}}=\frac{\mathbf{TP}}{\mathbf{TP+FP}}$

含义：模型预测为“目标”的结果中，真正是目标的比例（反映误检情况）。

（3）查全率（Recall）=$\frac{\text{某类正确检测数}}{\text{该类所有标注数}}=\frac{\mathbf{TP}}{\mathbf{TP+FN}}$

含义：所有真实目标中，被模型正确检测到的比例（反映漏检情况）。

（4）mAP（平均精度均值）=$\frac{1}{N}\sum_{i=1}^{N}\mathbf{AP_i}$

先计算每类的 AP（Precision-Recall 曲线下的面积），再对所有类别取平均。

是 COCO 等数据集的核心评测指标，综合反映模型的检测性能。

23. 改进型 IOU（解决传统 IOU 的局限性）

（1）GIOU（广义交并比）$=\mathbf{IOU}-\frac{\mathbf{Area(C)-Area(P\cup G)}}{\mathbf{Area(C)}}$

引入最小包围盒，取值范围[-1,1]：C 是 P 和 G 的最小包围盒。

（2）DIOU（距离交并比）$=\mathbf{IOU}-\frac{\boldsymbol{\rho}^2(\mathbf{b},\mathbf{b}^{\mathbf{gt}})}{\mathbf{c}^2}$

引入框中心的欧氏距离，取值范围[-1,1]：$\mathbf{b},\mathbf{b}^{\mathbf{gt}}$：预测框与真实框的中心，$\boldsymbol{\rho}$：欧氏距离，c：最小包围盒的对角线长度

（3）CIOU（完全交并比）$=\mathbf{IOU}-\frac{\boldsymbol{\rho}^2(\mathbf{b},\mathbf{b}^{\mathbf{gt}})}{\mathbf{c}^2}-\boldsymbol{\alpha}\mathbf{v}$

在 DIOU 基础上加入长宽比一致性惩罚，取值范围[-1,1]：α：权重系数v：长宽比差异系数，

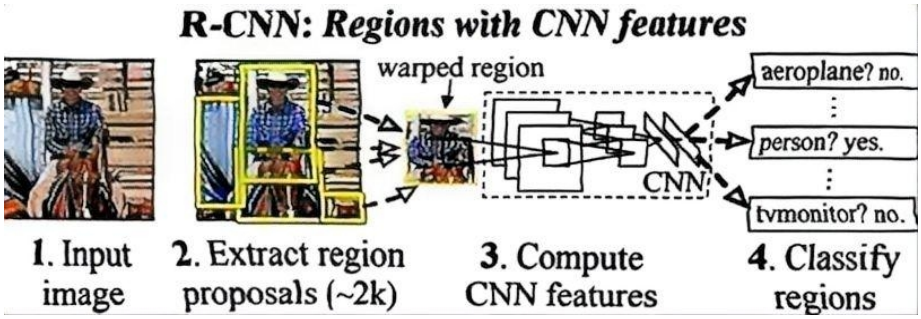
$\mathbf{v}=\frac{4}{\pi^2}\left(\arctan\frac{\mathbf{w}^{\mathbf{gt}}}{\mathbf{h}^{\mathbf{gt}}}-\arctan\frac{\mathbf{w}}{\mathbf{h}}\right)^2$，其中 w/h 是预测框宽高比，$\mathbf{w}^{\mathbf{gt}}/\mathbf{h}^{\mathbf{gt}}$是真实框宽高比

（4）SIOU 补充了角度、方向等几何关系的惩罚，进一步提升复杂场景下的框回归精度。

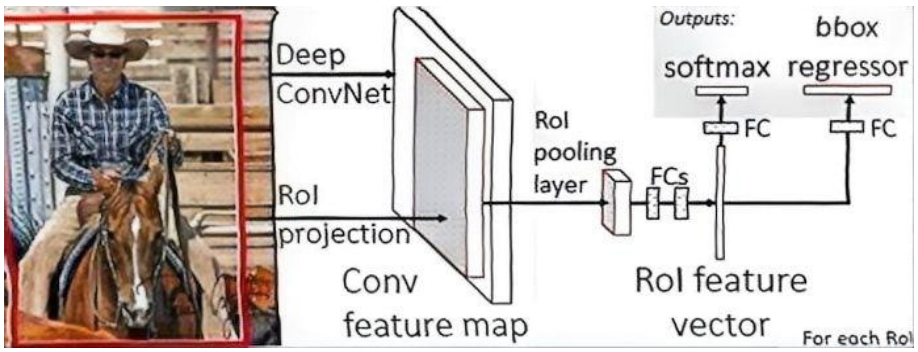
24.目标检测的挑战：精确定位与计数，更强的姿态变异性，遮挡定位，小目标检测

复杂度:假如图片大小 H×W，任取 2 个点作为检测框（不考虑同一条线），有$\mathbf{C}_{\mathbf{H}\times\mathbf{W}}^{\mathbf{2}}$种，复

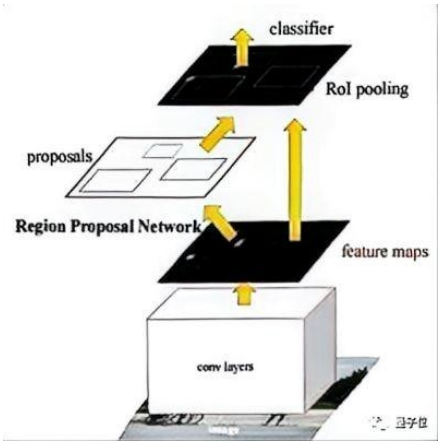
杂度为$\mathbf{O}((\mathbf{H}\times\mathbf{W})^2)$，不现实
改善：多尺度锚：在于预先设定一系列不同尺寸和宽高比的矩形框，覆盖可能存在的目标物体各种形态。在低分辨率的框放大到高分辨率误差会放大，所以尽量在高分辨率图像打标签
自适应锚：核心思想：不是人工预设锚框尺寸，而是用训练集中所有真实框的宽高，做 K-means 聚类，得到和数据分布最匹配的锚框集合。让锚框的尺寸更贴合实际数据，减少模型回归的难度，提升收敛速度和精度
25.目标检测架构
（1）R-CNN（2014）



输入图像 → 选择性搜索（生成约 2000 个候选框） → 每个候选框裁剪并缩放 → 单独送入 CNN 提取特征 → SVM 分类 + 边框回归
痛点：每个候选框都要单独跑一次 CNN，计算量极大、速度慢；需要单独存储特征和训练 SVM，流程繁琐。子图片中未必标注所需物体，分割子图那里没有学习（定位子图），可能有错误，并且算力要求大，模型速度慢
（2）Fast R-CNN（2015）



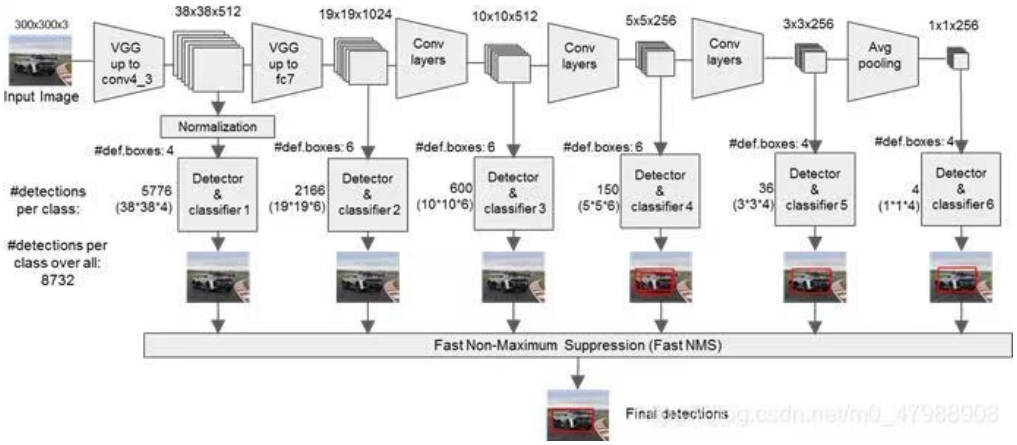
Softmax 是分类器，bbox regressor 可以进行框位置微调
核心改进：
整张图像只做一次 CNN 前向传播，生成共享特征图，避免重复计算
用 RoI Pooling 层（一种针对特征图的特殊池化操作，其核心特点是输入特征图尺寸不固定，但输出特征图尺寸固定），从共享特征图中直接提取每个候选框的固定长度特征
分类和回归都用全连接层（FC）完成，端到端训练，不再需要 SVM
遗留问题：候选框仍依赖选择性搜索算法，速度瓶颈依然存在。
优点：特征提取（一次），可以微调位置
（3）Faster R-CNN（2015）



核心改进：用 RPN（Region Proposal Network，区域候选网络）替代了选择性搜索，让候选框生成也变成了可学习的网络模块，真正实现了端到端

完整流程：图像 → 共享卷积层 → 特征图，RPN 在特征图上生成候选框和物体性分数，RoI Pooling 从特征图中提取候选框特征，最后分类 + 边框回归

（4）SSD



整体流程：输入图像 → VGG-16（Backbone） → 额外卷积层（多尺度特征图） → 每个特征图直接预测检测结果

特点：

利用不同下采样阶段的特征图做检测，兼顾大小目标（防止只保留高尺度特征太抽象）

可以看作「Backbone + 多尺度 Head」的结构，但还没有独立的 Neck 融合模块

（5）YOLOv1

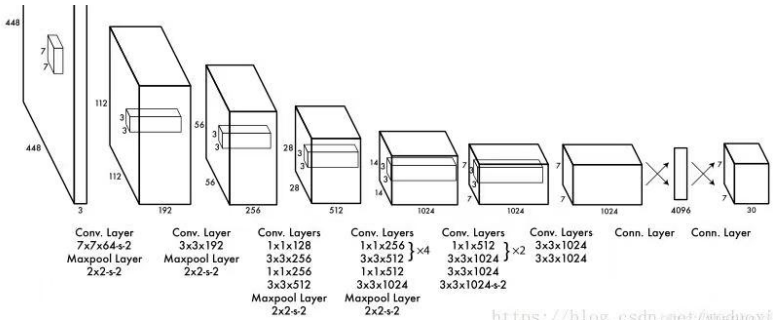
YOLOv1 是典型的一阶段检测，没有显式的候选框生成步骤，直接端到端完成预测。

整体流程：输入图像 → 卷积层（特征提取） → 全连接层 → 输出 7×7×30 的检测结果

特点：

没有像 Faster R-CNN 那样的 RPN 模块，直接在整张图上回归坐标和类别

结构相对简单，只有「特征提取 + 输出头」两部分，还没有明确的 Neck 模块



输入图像（448×448×3)--Backbone（卷积层，类似 GoogLeNet）24 个卷积层 + 2 个全连接层--全连接层输出→Reshape--最终输出张量：(7, 7, 30)

论文设定：

网格划分：7×7 网格（每个格子负责预测中心落在它里面的物体）

每个网格预测 2 个 bounding box

每个 bounding box 用 5 个数表示：x, y, w, h, confidence

x, y, w, h 分别中心点坐标和宽高，confidence 置信度，是是否有物体的概率

（6）三部分网络：Backbone + Neck + Head

主流目标检测模型（比如 YOLOv3/4/5/8、Faster R-CNN、RetinaNet 等）都被拆解为三个核心组件，对应 “特征提取、特征融合、特征输出”

组件	名称	核心作用	对应描述
Backbone	骨干网络	从原始图像中提取不同层级的基础特征（低层细节、高层语义）	特征提取
Neck	颈部网络	对 Backbone 的多尺度特征进行融合、增强（比如 FPN、PANet）	特征融合
Head	检测头	基于融合后的特征，完成目标的分类和定位回归	特征输出

优缺点对比：

模型	优点	缺点
R-CNN	1.首次将 CNN 用于检测，精度大幅提升 2.思路清晰，奠定两阶段范式	1.极慢：每个候选框都过 CNN2.多阶段训练，繁琐 3.占用显存大
FastR-CNN	1.比 R-CNN 快很多 2.单阶段训练，端到端 3.精度更高	1.仍用 SelectiveSearch 生成候选框 2.候选区域提取仍是瓶颈
FasterR-CNN	1.真正端到端，速度大幅提升 2.精度高，小目标效果好 3.两阶段标杆，通用性强	1.速度不如单阶段 2.后处理复杂，推理慢
SSD	1.速度比 FasterR-CNN 快很多 2.兼顾多尺度，大小目标都能测 3.单阶段，结构简洁	1.小目标精度不如 FasterR-CNN2.先验框设计较繁琐
YOLO(v1-v3)	1.速度极快，可实时 2.推理简单，全局上下文好	1.定位精度略低 2.小目标、密集目标较差 3.容易漏检

26.语义分割：语义分割是对图像逐像素进行分类，把图像上每一个像素都划分到对应的语义类别中，区分背景与各类物体。输入图片，输出与图片相等尺寸像素的分类

评价指标：IOU（某一类），mIOU（所有类平均 IOU）

网络结构：

（1）基本结构：图像-下采样-上采样-输出（输入和输出都是 H*W）

（2）图像金字塔：同一张图片，按不同分辨率缩放后，组成的一组图像集合，看起来像个金字塔

图像-上下采样-多尺度图像组-提取特征-特征融合（不同尺度特征图需进行尺度变换）

（3）特征金字塔：:不是原图的缩放，而是特征图的多尺度集合

图像-多尺度特征图-特征融合

特征融合方法：

（1）逐元素相加：两个特征图尺寸、通道数完全相同，对应位置的数值直接相加，不增加通道数，计算成本极低，没有额外参数

（2)通道拼接:两个特征图在通道维度上堆叠,空间尺寸不变,通道数相加。例:两个(H,W,C)的特征拼接后变成(H,W,2C)

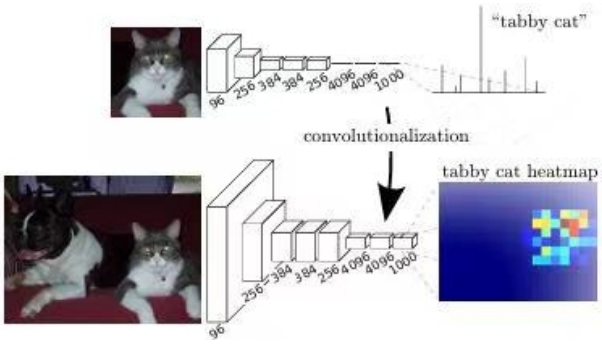
典型网络：

（1）FCN：先重复卷积，再把最后一层直接输出为 H*W，1*1 直接到 H*W

将传统 CNN 最后一次全连接层替换为 1*1 卷积层，通过转置卷积恢复到原来大小

优点：端到端，像素级检测，支持任意尺寸，缺点：模糊，缺乏空间一致性

改进：最后一层改为 1*1-2*2（并与前面 2*2 的特征图融合）-4*4（并与前面 4*4 的特征图融合）-...H*W



地位：语义分割的开山鼻祖

优点：结构最简单，第一次实现端到端像素级分割；去掉全连接层，输入图像尺寸可以任意；提出了跳跃连接思想，融合不同层特征；速度快、轻量化，适合理解基础原理

缺点：上采样用反卷积，边缘很模糊、很粗糙；没有对称解码结构，细节恢复差；对小目标、精细区域分割效果差；没有多尺度上下文建模能力

（2）U-Net

图像-数次卷积池化-数次上采样并与对应下采样的特征融合（拼接）-输出

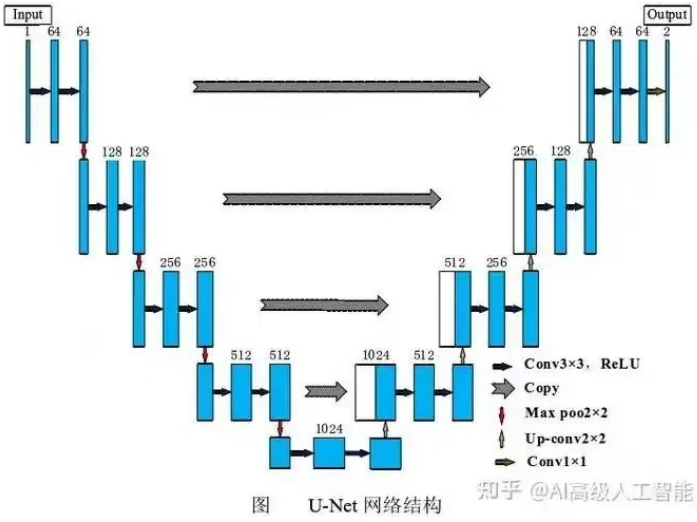


图　U-Net 网络结构

知乎 @AI高级人工智能

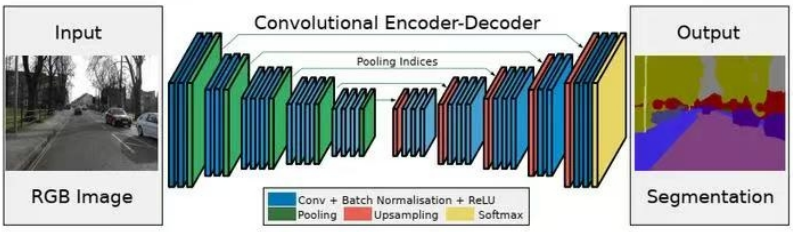
实现跳跃连接：把编码器前面的特征，直接 “跳” 到解码器对应层，和上采样后的特征融合在一起

地位：医学图像分割绝对王者

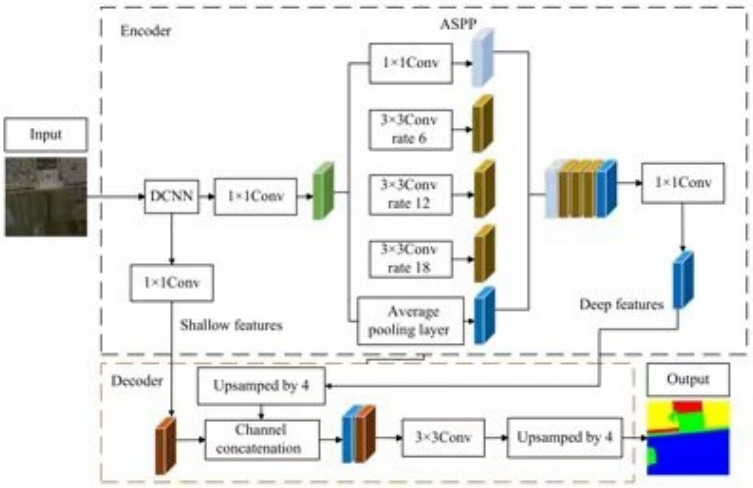
优点：对称 U 型结构，下采样 = 编码器，上采样 = 解码器；跳跃连接用 concat 拼接，保留大量细节；对小目标、边缘、医学影像效果极好；训练稳定，数据量少也能训得动；结构简单，容易魔改（U-Net++、3D U-Net 等）

缺点：没有多尺度上下文建模，对大物体、复杂场景一般；没有空洞卷积，感受野受限；参数量比 SegNet 大；对自然场景复杂目标不如 DeepLab 系列

（3）SegNet



编码器同 VGG16（无全连接），解码器：记录 max-pooling 位置索引，用来反池化，上采样不用学习，参数量小、省内存
优点：编码器和解码器完全对称；上采样用 max pooling 索引，不学习参数
参数量极小、速度快、省显存；适合嵌入式、实时分割
缺点：只传索引，不传特征，细节恢复差；分割精度明显低于 U-Net 和 DeepLab；没有多尺度融合，对复杂场景弱；边缘模糊，容易出现空洞
（4）DeepLabV3+：空洞卷积 + ASPP 多尺度 + Encoder-Decoder

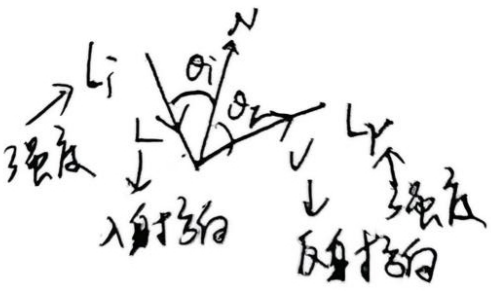


Encoder：带空洞卷积的 ResNet/Xception + ASPP（多尺度金字塔）
Decoder：融合低层细节 + 高层语义，细化边界
优点：结合 空洞卷积 +ASPP 多尺度上下文；感受野大，能捕捉全局信息；Encoder-Decoder 结构，融合低层细节；对复杂场景、大目标、小目标都很强；边界清晰，精度高，是 SOTA 级别的架构；通用性极强，自然图像分割首选
缺点：结构复杂，参数量大；速度比 FCN、SegNet 慢；对算力要求高，不适合极端轻量场景；训练相对麻烦一些
27.立体视觉：从二维图像中提取信息

相机内外参：相机外参$\vec{x}_{img} = K[R \quad \vec{t}]\vec{X}_w$，相机内参$\vec{x}_{img}=P\vec{X}_w$

举例$K = \begin{bmatrix} 1 & & tu \\ & 1 & tv \\ & & 1 \end{bmatrix}$，$K = \begin{bmatrix} Sx & & tu \\ & Sy & tv \\ & & 1 \end{bmatrix}$，$K = \begin{bmatrix} Sx & a & tu \\ & Sy & tv \\ & & 1 \end{bmatrix}$

照片中的像素反映光线的辐射信息（例如物体本身表面信息，颜色，纹理）



朗伯模型：$Lr = \rho(\theta i, \theta r)Licos\theta i$,其中$\rho(\theta i, \theta r)$是双向反射函数，表示某类材料性质。镜面反射只有在$\theta i = \theta r$时$\rho$才有值，否则$\rho=0$；漫反射$\rho(\theta i, \theta r)=\rho$(常数)，$\rho$是常量，也就是$Lr = \rho Licos\theta i=\rho Li\overrightarrow{LN}$,其中$\vec{L}$

为入射方向，$\vec{N}$为法线方向

$\mathbf{I(x,y)=\rho(x,y)Li\overrightarrow{LN}(x,y)}$,其中$\mathbf{I(x,y)}$为图片上像素的强度（亮度值），$\boldsymbol{\rho}(x,y)$是反射组分，可假设$\boldsymbol{\rho}$不变，$\mathbf{Li\overrightarrow{LN}}(x,y)$是照射组分，$\mathbf{Li\vec{L}}$是不变量，也就是只要知道所有的$\vec{N}(x,y)$，就变相知道物体形状

28.同态滤波（压制照射组分，使低光照的图像增强，解决光照不均问题，消除光照不同的影响）

$$f(x,y)=fi(x,y)fr(x,y)\rightarrow z(x,y)=lnf(x,y)\rightarrow z(u,v)$$

$$=FFTz(x,y)\rightarrow 滤波\rightarrow S(u,v)$$

$$=H(u,v)z(u,v),其中H(u,v)$$

$$=(Y_H-Y_L)[1-exp\left[-c\frac{D^2(u,v)}{D_0^2}\right]+Y_L\rightarrow S(x,y)$$

$$=IFFTS(u,v),g(x,y)=expS(x,y)$$

YH＞1 表示增强高频，提升边缘、细节等，YL＜1 表示衰减低频，减弱不均匀光照的影响，C 表示锐利度，D(u,v)表示频率中心距离，D0 为截止频率

直方图均衡化：解决对比度不足的问题，Pr(rk)b 表示 rk 出现概率，rk 是第 k 个灰度级（0-255），nk 是灰度为 k 的像素总数，Sk 的运算是把原 rk 灰度级映射到 Sk

$$Pr(rk)=\frac{nk}{n},Sk=T(rk)=255\sum_{j=0}^{k}Pr(rj)$$

29.推导：对于$\mathbf{I(x,y)=\rho(x,y)Li\overrightarrow{LN}(x,y)}$，假设光源强度 Li 为 1,那么$\mathbf{I=\rho\overrightarrow{LN}=\rho\overrightarrow{N}^T\overrightarrow{L}}$，其中$\vec{N}$在三维空间中自由度为 2，原因是其为方向向量，只要知道两个分量再联立模长为 1 可求第三个分量。上式可令$\mathbf{G=\rho\vec{N}}$，于是$\mathbf{I=\vec{G}^T\vec{L}=\vec{L}^T\vec{G}}$其中 G 为 N 维，在三维场景下 N=3，模长为ρ，方向与$\vec{N}$一致.如果用多个不同方向的光源拍摄同一场景，可得多个亮度方程，联立可求 G 进而分离出ρ与$\vec{N}$。即$\mathbf{I1=\overrightarrow{L1}^T\vec{G}}$，$\mathbf{I2=\overrightarrow{L2}^T\vec{G}...Ik=\overrightarrow{Lk}^T\vec{G}}$，这些式子表达相机位置不变只改变光源方向

当 k≥3 时超定，使用最小二乘求解，其中 L 是 3*k，I 是 k*1，G 是 3*1，

目标函数$\min_{\mathbf{G}}\|\mathbf{I-L^TG}\|^2=\min_{\mathbf{G}}(\mathbf{I^TI+G^TLL^TG-2G^TLI})$

对 G 求导$\mathbf{2LL^TG-2LI=0\Rightarrow G=(LL^T)^{-1}LI}$（仅对一个像素点）

对于多像素点：$\mathbf{I^{(1)}=\vec{L}^T\overrightarrow{G^{(1)}}...I^{(n)}=\vec{L}^T\overrightarrow{G^{(n)}}}$，于是

$\left[\mathbf{I}^{(1)},\ \mathbf{I}^{(2)}\ldots\mathbf{I}^{(n)}\right]=\vec{\mathbf{L}}^{\mathbf{T}}\left[\overrightarrow{\mathbf{G}^{(1)}},\ \overrightarrow{\mathbf{G}^{(2)}}\ldots\overrightarrow{\mathbf{G}^{(n)}}\right]$,同样为$\mathbf{I}=\vec{\mathbf{L}}^{\mathbf{T}}\vec{\mathbf{G}}$，但是此时 I 是 k*n，代表多视角多点位，$L^T$ 为 k*3 不变，G 为 3*n

30.三维数据=二维数据+深度信息，其最小单元称为体素，举例：点云，多边形网格，数据集:shape net;解决三维信息丢失，采用结构光成像：$\mathbf{d}=\frac{\mathbf{c}}{\mathbf{2}}*\mathbf{tp}*\frac{\mathbf{S1}}{\mathbf{S0}+\mathbf{S1}}$，tp 为时间差，c 为光速

31.二维图像数据可能存在的问题：透视问题，深度维度信息丢失

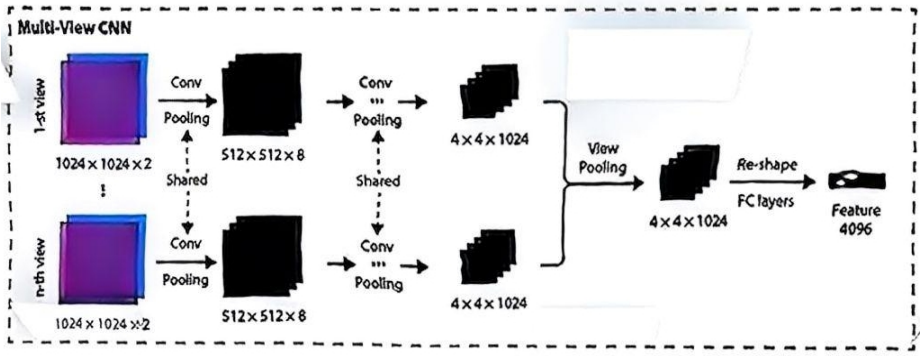
32.对单个建筑三维建模网络结构：图像--卷积（可以多层）--向量化--拆为几何向量（求 G）和纹理向量（解码 RGB）--融合为模型

从数据中寻找知识网络（Bitree net）：

多视角图像数据--多视角 CNN--特征图 ↓

粗糙点云--点云网络--3D 点特征　　→→递归二叉树--信息

其中多视角 CNN：



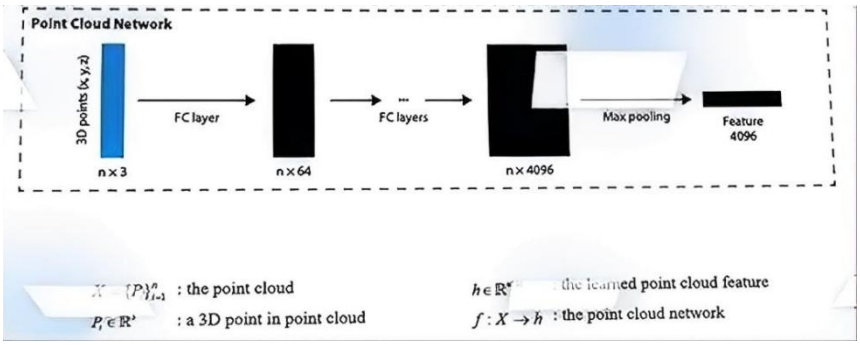
$X=\{I_i\}_{i=1}^{n}$: multi-view images

$I_i\in\mathbb{R}^{1024\times1024\times2}$: a single-view two-channel image

$h\in\mathbb{R}^{4096}$: the learned image feature

$f: X\to h$: the multi-view CNN

点云网络：



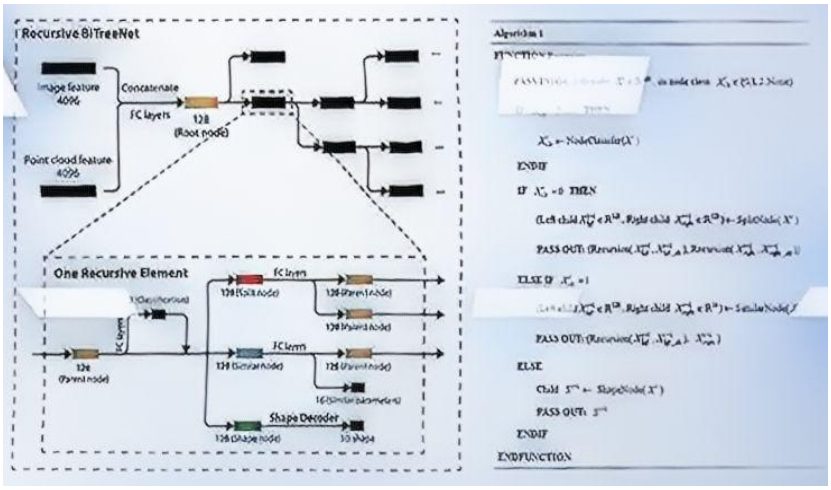
$X=\{P_i\}_{i=1}^{n}$: the point cloud

$P_i\in\mathbb{R}^3$: a 3D point in point cloud

$h\in\mathbb{R}^{4096}$: the learned point cloud feature

$f: X\to h$: the point cloud network

递归二叉树：



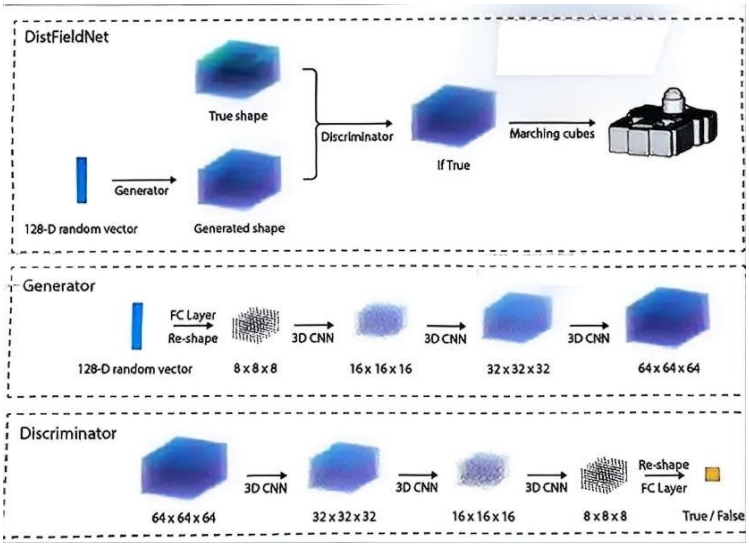
损失函数：

节点分类损失$\mathbf{L_{cls}} = -\sum_{\mathbf{i}\in\{1,\ldots,\mathbf{n}\}}\sum_{\mathbf{x}\in\mathbf{X}}\mathbf{p_i}(\mathbf{x})\log\mathbf{q_i}(\mathbf{x})$ 3D 形状损失

$\mathbf{L_{shape}} = -\sum_{\mathbf{i}\in\{1,\ldots,\mathbf{n}\}}\mathbf{dist}(\mathbf{M_i^{gt}}, \mathbf{M_i^{pred}})$ 形状距离$\mathbf{dist}(\mathbf{M_1}, \mathbf{M_2}) = \sum_{\mathbf{v_1}\in\mathbf{M_1}}\min_{\mathbf{v_2}\in\mathbf{M_2}}\|\mathbf{v_1}-\mathbf{v_2}\|_2^2 + \sum_{\mathbf{v_2}\in\mathbf{M_2}}\min_{\mathbf{v_1}\in\mathbf{M_1}}\|\mathbf{v_1}-\mathbf{v_2}\|_2^2$ 相似参数损失$\mathbf{L_{sim}} = \sum_{\mathbf{i}\in\{1,\ldots,\mathbf{n}\}}\|\mathbf{S_i^{pred}} - \mathbf{S_i^{gt}}\|_2$

总损失$\mathbf{L} = \boldsymbol{\lambda}_{\mathbf{cls}}\mathbf{L_{cls}} + \boldsymbol{\lambda}_{\mathbf{shape}}\mathbf{L_{shape}} + \boldsymbol{\lambda}_{\mathbf{sim}}\mathbf{L_{sim}}$

GAN 三维生成对抗网络：



整体架构：DistFieldNet（基于距离场的 3D-GAN）

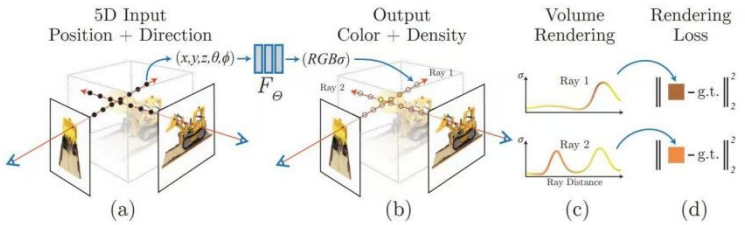
核心流程：从随机向量生成 3D 距离场，通过对抗训练优化，最终用 Marching Cubes 算法重建出三维网格模型。

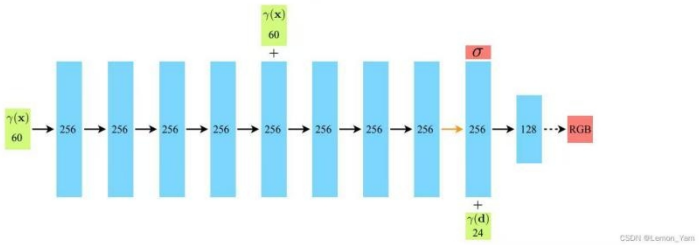
生成器（Generator）流程

输入：128 维随机向量

处理：经过全连接层 + Reshape，先变成 8×8×8 的体素，再通过 3D CNN 逐层上采样，最终生成 64×64×64 的距离场体素

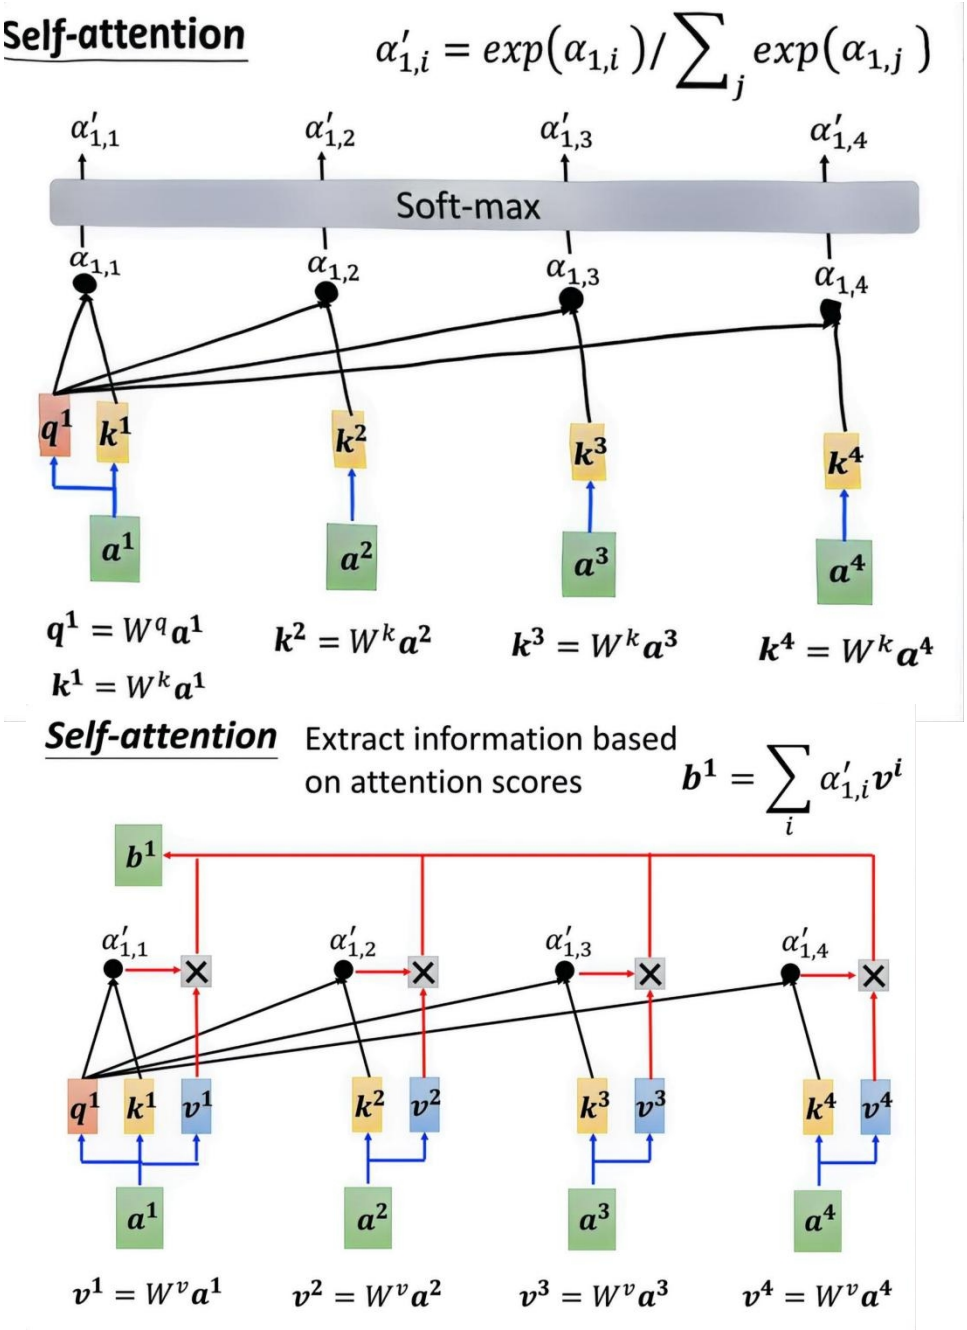
判别器（Discriminator）流程
输入：真实 / 生成的 64×64×64 距离场体素
处理：通过 3D CNN 逐层下采样，最终输出“True/False”的真伪判断
后处理：Marching Cubes（移动立方体算法）
作用：将生成的距离场体素，重建为带表面的三维网格模型，得到最终的 3D 形状输出。
33.NerF:输入空间坐标+视角，网络直接预测该点颜色 RGB、体密度 σ；整个场景的几何、材质、光照全部编码在神经网络权重里，这就是“神经”的根源。



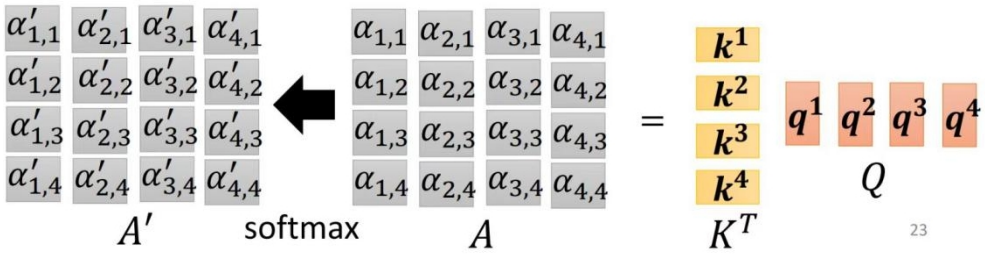


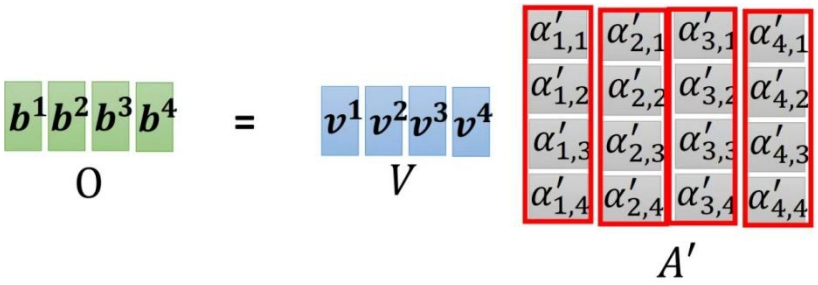
输入：多视角图像 + 已知相机位姿
光线生成：对每个像素发射一条光线，穿过 3D 场景
分层采样：在光线上采粗 / 细两类点（Hierarchical sampling）
位置编码：将 (x,y,z) 位置、视角方向 (θ,φ) (自由度 2，模长 1)做高频编码
MLP 网络：输入编码 → 输出该点 颜色 RGB + 体密度 σ
体渲染：沿光线积分颜色 / 密度 → 合成该像素颜色
损失：与真实图对比，优化 MLP 权重
实现使用少量的多视角图输入，对一个连续的隐式体积场景函数进行优化，对复杂场景图进行合成，可生成新视角图。输入连续 5D 坐标，输出光线上任意位置颜色 c=（r，g，b）和体积密度σ（代表累积透过率）
34.注意力机制：传统网络（如全连接）难以考虑上下文影响，如果采用窗口框住输入序列，窗口长度难以确定，如果窗口过长会导致计算量太大
注意力机制输入内容需向量化，每个向量都要有标签
计算过程：

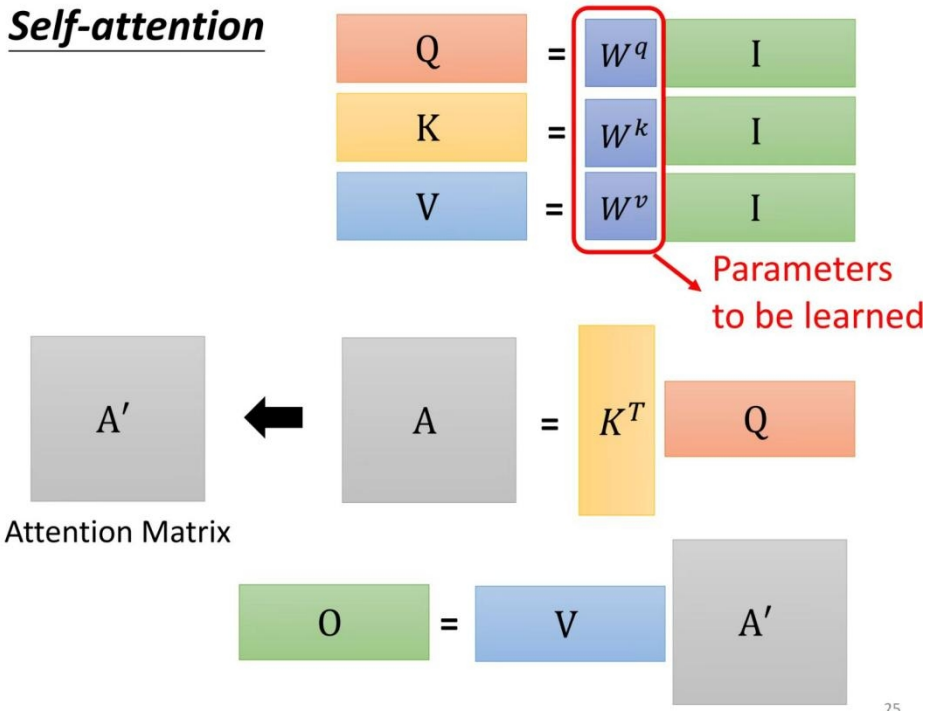
先查询 a1，q1=Wq*a1，然后生成键 k1=Wk*a1...k4=Wk*a4，然后 q1 和 k1 到 k4 分别求余弦相似度得到 α 1,1... α 1,4，然后 softmax 归一化 α' 1,1... α' 1,4, 然后生成值 v1=Wv*a1...v4=Wv*a4，最后加权求和，b1=α' 1,1*V1+...+α' 1,4*V4，计算过程中完全可以并行计算 b1 到 b4



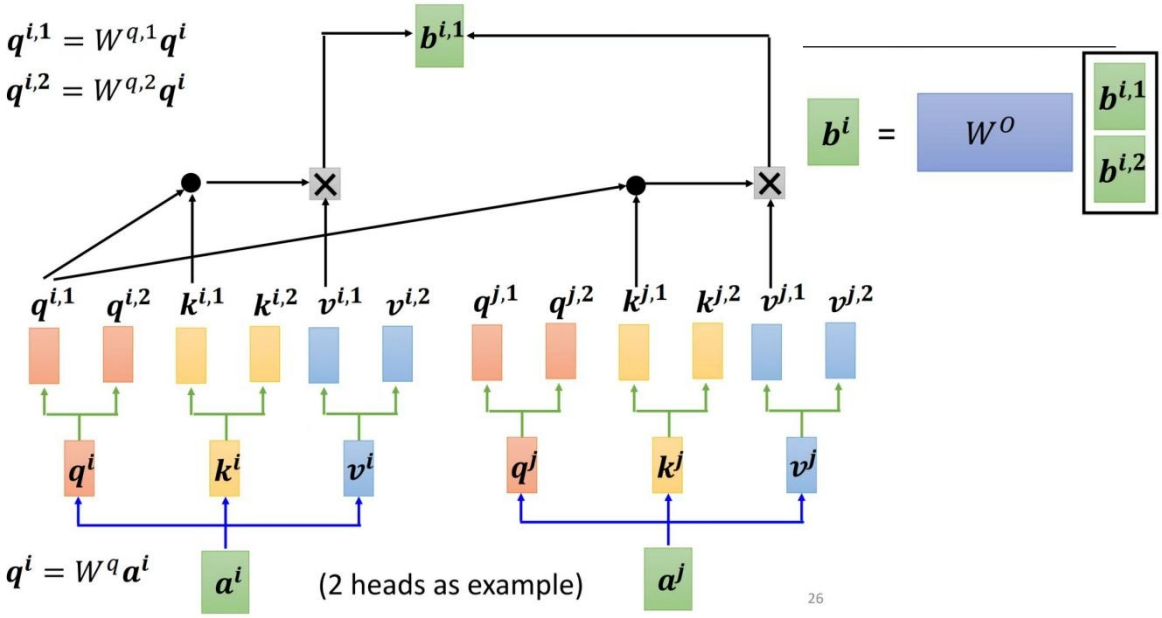
矩阵表示（为求解余弦相似度,Wk 与 Wq 矩阵长宽应一致，Wr 没有限制）：







35.多头注意力机制（有多个 q，k，v），计算时 q 与 k 作用的位置应当固定，例如 qi，1 只与 ki，1 作用，不与 ki，2 作用，模型最后输出很多 b，例如 bi，1，bi，2，将这些 bi，k 拼起来左乘一个维度转换的矩阵　　W0 得到规定维度的 bi。考试如果出来需要从单头开始画



36.注意力与 CNN：CNN 通过卷积核考虑不同位置相关性，如果卷积核过小很难考虑相关性；CNN 中也可以加入注意力机制；当参数量较少 CNN 更准确反之基于 Transformer 的注意力更准；注意力的优势在于并行计算

37.Transformer：编码器 + 解码器结构

Encoder（编码器）：把输入（如中文句子）转成上下文特征。

Decoder（解码器）：用 Encoder 特征生成输出（如英文翻译）

具体结构：

1. 词嵌入 + 位置编码　Embedding：把词转成向量。　Positional Encoding：因为没有循环，要手动加入顺序信息。

2. 多头自注意力　并行做多组注意力，捕捉不同类型的语义关系（如语法、指代、逻辑）。

3. Encoder 层（重复 N 层，通常 6 层）

每一层包含：多头自注意力　前馈网络（FFN）：两层线性变换 + 激活

残差连接 + 层归一化：稳定训练、防止梯度消失

4. Decoder 层（重复 N 层）

比 Encoder 多一个掩码注意力 + 交叉注意力：

Masked 自注意力：解码时看不到未来的词。　交叉注意力：关注 Encoder 输出（建立输入 — 输出关联）。　前馈网络 + 残差 / 归一化。

四、主要优势

并行计算；长距离依赖强：直接建模全局关系；灵活通用：可用于文本、图像、语音、多模态。

五、主流衍生模型

Encoder 为主：BERT（理解、分类、抽取）。　Decoder 为主：GPT、GPT-4、Claude。

38.图像自回归（不需打标签）

图像-切成 patch 并对齐-对 patch 随机遮挡-生成序列+位置编码-编码-解码-回归出遮挡图像

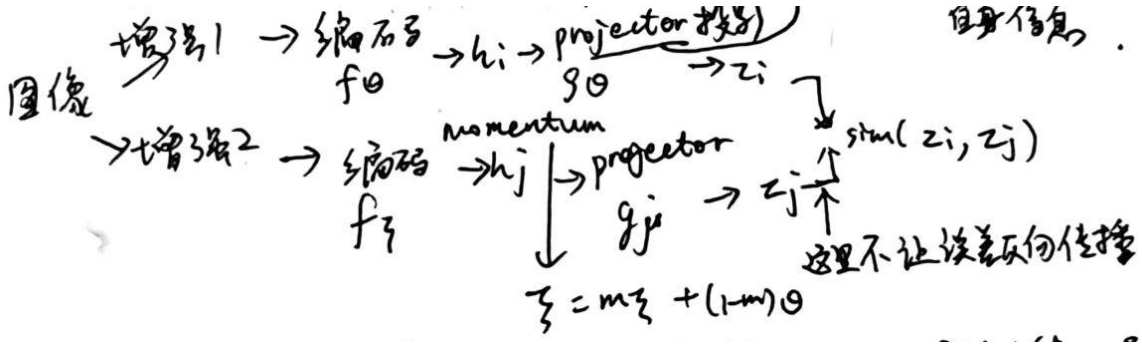
图像大模型：去噪，去雨线，超分辨（上采样）：图片-patch-特征图-编码-解码-还原

大模型：数据（多模态：文本，图片，语音）-tokenize-基础模型-下游任务
CNN 通过滑动卷积建模空间相关性，transformer 通过序列建模空间相关性
39.gato 模型：可预测动作，覆盖文本，视觉，游戏等任务
数据（文本，图片，交互动作，问答内容等）-batch、遮挡-Gato-L（O,B）
大模型关键点：1.基础理论-注意力 2.下一代大模型-数学 3.大模型效率-云上学习
4.快速自适应能力 5.模型可控 6.安全、伦理 7.自进化（灵光一闪，解决其他领域问题）
8.创新应用 9.模型评测（不同任务指标不同） 10.模型集成
40.对比学习（视觉领域自回归模型）
（1）InstDisc：把数据集中的每一张图片，都当成一个独立的 “类别”，让模型学习区分每一个不同的实例。通过这种方式，迫使模型学习到能捕捉视觉相似性的、区分度极高的特征表示。
步骤：输入一张图片（比如图中的豹子），经过卷积神经网络（CNN），先输出一个高维特征向量（2048D），再降维到 128D，把图像信息压缩成一个向量表示。对 128 维的特征向量做 L2 归一化，让它落在单位超球面（128D Unit Sphere）上。通过对比相似度来做 “分类”。把数据集中所有样本的特征向量，都提前存到一个 “记忆库” 里。
（2）InvaSpread：端到端实例判别对比学习，SimCLR 前身。图片及其图片增强为正样本，与 batch 内其他图片构成负样本：图片及其增强-CNN-特征（每个图片及其增强在特征空间更近）
（3）MoCov1（又称教师-学生网络）

思想：学生路径：$x^{query} \rightarrow encoder \rightarrow q$；教师路径（queue）：$x_0^{key}$，$x_1^{key} \ldots \rightarrow encoder - k0, k1 \ldots$

最后 q 与 k0，k1...求 similarity。X0 到 xn 中有一个是 xq 的增强（正样本 k+），其余为负样本，学生网络允许误差反传，更新快，教师网络通过 momentum 更新：$\theta k \leftarrow m\theta k + (1 - m)\theta q$,更新的更为稳定，$\theta q$为学生网络的信息，教师网络通过学生更新，但是保留一部分本身信息θk

对比损失为$Lq = -\log \frac{exp(q*k+/\tau)}{\sum_{i=0}^{k} exp(q*ki/\tau)}$， Projector 一般为 2 层 FC（提出时为 1 层）



（3）SimCLR v1：极简端到端对比学习，编码器采用 ResNet（预训练好了），只需训练投影头（2 层 mlp）。无队列、无动量编码器、无 Memory Bank
（4）MoCo v2=MoCov1+SimCLR v1，Query 在线编码器 + Momentum 动量编码器，动量更新公式不变；Queue 队列结构完全保留，投影头从单层 FC → 改成两层 MLP

（5）SwAV：ResNet 作为共享编码器，无双编码器、无动量、无队列，纯端到端，投影头三层 MLP；Prototype 原型矩阵（聚类中心）：全局可学习原型向量集合 C，相当于动态聚类中心

41.无负样本（视觉领域自回归模型）：采用跨层级相似度，两个分支的 MLP 投影头结构不一样

（1）BYOL：网络结构:

双分支结构：

在线网络（Online）：ResNet 编码器 f_θ → 投影头 g_θ → 预测头 q_θ（额外加的 MLP）

目标网络（Target）：ResNet 编码器 f_ξ → 投影头 g_ξ（无预测头，权重由在线网络 EMA 更新）

输入图像 x→两个增强视图 v,v′视图 1 走在线网络，得到 $q_\theta(z_\theta)$；视图 2 走目标网络，得到 $sg(z_{\xi'})$（stop-gradient，停止梯度回传） 损失：两个特征的余弦相似度损失（最大化相似度）

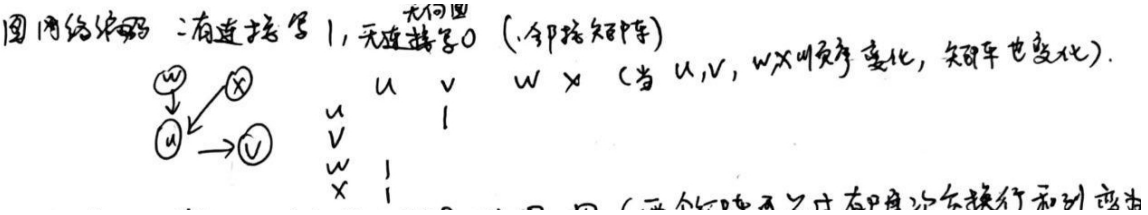
更新规则：在线网络用梯度更新；目标网络用动量更新：$\xi \leftarrow \tau\xi+(1-\tau)\theta$

（2）SimSiam：极简无监督对比学习：去掉动量更新，只用 stop-gradient + 预测头

42.图神经网络（GNN）

图：G=(V,E),V 是节点集合，E 是边集合；节点特征：$\boldsymbol{X} \in \mathbb{R}^{\boldsymbol{d}*|\boldsymbol{V}|}$;隐层嵌入$\boldsymbol{h} = \{\overrightarrow{h_1}, \overrightarrow{h_2}, \ldots, \overrightarrow{h_N}\}$；节点嵌入$z_u, \forall u \in V$；边嵌入$h_{(u,v)}^{(k)}, (u,v) \in E$

隐层嵌入表示 GNN 经过一层或多层信息传递后节点最终形成的向量表示；节点嵌入是单个节点的低维向量表示，边嵌入是一条边（u，v）的向量表示



图拓扑表示：判断两个矩阵是否表示同一张图，只需判断是否经过有限次行列变换为同一矩阵

采样不变性：$f(PAP^T)=f(A)$，输入经过初等变换后输出仍为 A 矩阵，例如分类

等变性 $f(PAP^T)=Pf(A)$，输入经过变换后输出也会变换，例如目标检测，语义分割

图信息传递：输入图-聚合-更新

$$h_u^{(k+1)} = UPDATE^{(k)}\left(h_u^{(k)}, AGGREGATE^{(k)}\left(\{h_v^{(k)}, \forall v \in \mathcal{N}(u)\}\right)\right)$$

U 是目标节点（当前正在更新），k 是层数，$h_u^{(k)}$是节点自身特征，$h_v^{(k)}$是邻居特征，简化公式$\boldsymbol{h_u^{(k+1)} = UPDATE^{(k)}\left(h_u^{(k)}, m_{\mathcal{N}(u)}^{(k)}\right)}$，$\boldsymbol{m_{\mathcal{N}(u)}^{(k)}}$是对邻居聚合后的消息向量

$$\boldsymbol{h_u^{(k-1)} = \sigma(\mathbf{W}_{\mathbf{self}}^{(\mathbf{k})} h_u^{(k+1)} + \mathbf{W}_{\mathbf{neigh}}^{(\mathbf{k})} \sum_{\mathbf{V}\in\mathcal{N}(u)} h_v^{(k-1)} + \mathbf{b}^{(\mathbf{k})})},$$

$h_u^{(k-1)}$是节点 u 在上一层嵌入向量，$\sum_{V\in\mathcal{N}(u)} h_v^{(k-1)}$是邻居 v 在上一层嵌入向量之和，$W_{self}^{(k)}$是节点自身信息的权重矩阵，可学习，$W_{neigh}^{(k)}$是邻居聚合信息的权重矩阵，可学习，$b^{(k)}$是偏置，可学习

$$\boldsymbol{h_u^{(k-1)} = \sigma(W_{self}^{(k)} h_u^{(k+1)} + W_{neigh}^{(k)} \sum_{V\in\mathcal{N}(u)} h_v^{(k-1)} + b^{(k)})}$$

将图网络中每个节点都看做图像中的点，可以类比卷积核，hu 指的是第 u 位置的点，$V\in\mathcal{N}(u)$类比卷积核窗口，Wself 代表卷积核中心点参数，其他邻域点是 Wneigh，加一个偏置 b

图学习任务：节点级（过滤），图级（池化）；图节点池化：多个节点-少量节点（缩聚为小图）

图节点滤波：将 n 个节点滤成子图；图注意力机制：用 softmax 推断节点重要性

$$\alpha_{ij} = \frac{\exp\left(LeakyReLU\left(\mathbf{a}^{\top}[\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]\right)\right)}{\sum_{k\in\mathcal{N}(i)\cup\{i\}} \exp\left(LeakyReLU(\mathbf{a}^{\top}[\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_k])\right)}$$

43.深度生成学习：给定{Xn}，得到 X 的分布 P（x），再采样生成数据 sample

AE 自编码器：学习输入数据的紧致特征表示（隐向量），无概率建模，仅做确定性的特征映射

仅包含编码器、隐层、解码器三部分，全程为确定性计算，无随机采样步骤；编码器：高维输入 → 低维隐向量；隐层是输入数据的紧致特征表示；解码器：低维隐向量 → 高维重构输入

变分自编码器 VAE：学习数据的概率分布，既能像自编码器一样重构输入，又能从学习到的分布中采样生成新数据（变分体现于对分布进行采样）

真实样本-求均值方差-分布-采样-生成器-生成样本，再将生成样本和真实样本对比

44.JS 散度:是 KL 散度的对称修正版,KL 散度具有非对称的局限。

$\mathbf{KL(p||q) = H(p,q) - H(p) = \sum_x P(x) \log \frac{P(x)}{q(x)}}$基于两个分布的平均分布$\boldsymbol{M = \frac{1}{2}(P+Q)}$计算：$\boldsymbol{JSD(P||Q) = \frac{1}{2}KL(P||M) + \frac{1}{2}KL(Q||M)}$也可以写成：$\boldsymbol{JSD(P||Q) = \frac{1}{2}\sum_x p(x) \log \frac{p(x)}{\frac{p(x)+q(x)}{2}} + \frac{1}{2}\sum_x q(x) \log \frac{q(x)}{\frac{p(x)+q(x)}{2}}}$=$\boldsymbol{\frac{1}{2}\sum_x p(x) \log \frac{p(x)}{p(x)+q(x)} + \frac{1}{2}\sum_x q(x) \log \frac{q(x)}{p(x)+q(x)} + log2}$值域[0,1],当 p 与 q 不相等时为常值 log2

W 距离：将 p 与 q 切成一堆一堆，p 与 q 越接近，那一堆一堆的高度也越近，每一堆匀一匀使得 p 与 q 接近，匀的过程（切割、转移）做的功要越小越好，fij 表示转移的量，（xi-xj）fij 表示做功，移的土不能超过自己的量：$\sum fij<pj, \sum fij<qj$

$$EMD(P,Q)=\min_{f_{ij}}\left(\frac{\sum_{i=1}^{u}\sum_{j=1}^{v}d_{ij}f_{ij}}{\sum_{i=1}^{u}\sum_{j=1}^{v}f_{ij}}\right),\sum_j f_{ij}\le w_{r_i},\sum_i f_{ij}\le w_{s_j},$$

$f_{ij}\ge 0$ 第一个约束表示从 i 运出的土不能超过 i 的总量，第二个约束运到 j 的土不能超过 j 的容量

$$EMD(P,Q)=\min_{f_{ij}}\left(\frac{\sum_{i=1}^{N}\sum_{j=1}^{N}|x_i-x_j|f_{ij}}{\sum_{i=1}^{N}\sum_{j=1}^{N}f_{ij}}\right),\ \sum_j f_{ij}\le p_i,\ \sum_i f_{ij}\le q_j,$$

一维形式，距离 dij 用 xi-xj 表示

45.GAN 生成对抗网络：将真实图片和生成器生成的图片先输入给判别器训练判别器能力，再固定判别器，训练生成器能力，再固定生成器训练判别器...循环数次得到高精度判别器和生成器

极小极大博弈：$\min_G\max_D V(D,G)$； 判别器（让真实数据尽可能被判为 1，生成数据尽可能被判为 0）最大化 V(D,G),生成器最小化 V(D,G)（让生成数据尽可能被判为 1）

$$\boldsymbol{V(D,G)=\mathbb{E}_{x\sim p(x)}[\log D(x)]+\mathbb{E}_{z\sim q(z)}[\log(1-D(G(z)))]}$$

纳什均衡：$\boldsymbol{P_{data}(x)=P_{gen}(x)}$（分布完全重合），$\boldsymbol{D(x)=\frac{1}{2},\forall x}$（判别器处于 “50%” 状态）

如果采用 JS 散度，当两分布无重叠，JS=log2，导致判别器梯度消失,如果采用 W 距离，即便无重合也可判断距离

WGAN-GP(采用 W 距离的 GAN);WGAN 要求判别器满足 1-Lipschitz 连续性（梯度范数不超过 1）,两种实现方式：

(1)权重裁剪:把判别器的权重强制限制在区间[−c,c]内，即 w=clip(w;−c;c),实现简单，但属于粗粒度约束，容易导致梯度消失、模型容量下降，训练震荡

(2)梯度惩罚:在损失函数中加入正则项：$\lambda\mathbb{E}_{\hat{x}\sim P_{\hat{x}}}\left[\left(\left\|\nabla_{\hat{x}}D(\hat{x})\right\|_2-1\right)^2\right]$， 强制梯度范数接近于 1，不破坏模型表达能力，训练更稳定，生成质量更高

46.GAN 的应用：pix2pix GAN（给出语义标签生成原始结构，例如给出简笔画生成图片）

Cycle GAN：x 生成 y 估，再由 y 估生成 x 估；y 生成 x 估，再由 x 估生成 y 估；理论上两条路径中 x 与 x 估，y 与 y 估应该一样，损失函数$||\boldsymbol{F(G(X))-X}||_1,||\boldsymbol{G(F(Y))-Y}||_1$

在土木应用：智能设计模型

47.扩散模型：真实图片不断加入噪声得到纯噪声图片（扩散），纯噪声图片不断去噪得到一个清晰图像（重构），这个过程可以加入时间序列。推导结果：

1. x_{t-1}分布的均值和方差已经求得，其中方差是由已知参数表示的定量，均值由x_t与添

加的噪声$\overline{Z}_t$表示：$\boldsymbol{\delta^2 = \frac{1-\overline{\alpha}_{t-1}}{1-\overline{\alpha}_t}\beta_t}$，　$\boldsymbol{\mu(x_0, x_t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\overline{\alpha}_t}}\overline{Z}_t\right)}$

2. 将求解去噪后图像的问题等价为求解添加噪声的问题，建立预测噪声的模型$\boldsymbol{\varepsilon_\theta(x_t)}$，正向扩散过程加入的噪声为 **ground truth**，模型的训练过程及预测过程：

训练过程（**Algorithm 1 Training**）

1. 重复以下步骤直到收敛：**2.** 从真实数据分布采样：$x_0 \sim q(x_0)$**3.** 从时间步均匀分布采样：$\boldsymbol{t \sim Uniform(\{1, \ldots, T\})}$**4.** 采样标准正态噪声：$\epsilon \sim \mathcal{N}(0, \mathbf{I})$**5.** 对目标函数执行梯度下降：$\nabla_\theta \left\| \epsilon - \epsilon_\theta \left(\sqrt{\overline{\alpha}_t} x_0 + \sqrt{1-\overline{\alpha}_t}\, \epsilon, t \right) \right\|^2$

采样过程（**Algorithm 2 Sampling**）

1. 初始化噪声：$x_T \sim \mathcal{N}(0, \mathbf{I})$ **2.** 从 **t=T** 到 **1** 循环：若 **t>1**，则$Z \sim \mathcal{N}(0, \mathbf{I})$；否则 **z=0**，更新$x_{t-1}$：$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\overline{\alpha}_t}}\epsilon_\theta(x_t, t)\right) + \sigma_t z$ **3.** 返回生成结果x_0